



UNIwersYTET GDAŃSKI

Maciej Sochacki
Nr albumu: 291767

Ekonometryczna analiza determinant wartości rynkowej piłkarzy w czołowych ligach europejskich

Kierunek studiów: Informatyka i ekonometria
Poziom studiów: I stopnia - licencjackie
Profil studiów: ogólnoakademicki
Forma studiów: studia stacjonarne

Praca dyplomowa licencjacka
wykonana pod kierunkiem
dr Marta Chylińska

Gdańsk, 2026 r.

Spis treści

Wstęp	2
Rozdział 1. Teoretyczne podstawy wyceny zawodników na rynku transferowym	4
1.1. Specyfika rynku transferowego w piłce nożnej	4
1.2. Kapitał ludzki w analizie wyceny zawodników	6
1.3. Determinanty wartości transferowej	8
1.4. Stan badań	9
Rozdział 2. Metodyka badania i charakterystyka danych	12
2.1. Cel i hipotezy badawcze	12
2.2. Charakterystyka próby i źródeł danych	12
2.3. Konstrukcja i transformacja zmiennych	15
2.4. Statystyki opisowe próby	17
2.5. Postać analityczna modelu	18
Rozdział 3. Wyniki badań empirycznych	20
3.1. Wyniki estymacji i interpretacja parametrów modelu	20
3.2. Walidacja modelu	24
3.3. Empiryczny obraz kluczowych wyznaczników	28
3.4. Analiza reszt i zawodnicy odstający od wyceny	30
3.5. Weryfikacja hipotez badawczych	32
Zakończenie	35
Bibliografia	37
Książki i artykuły naukowe	37
Źródła internetowe	38
Spis tabel	39
Spis rysunków	40
Załączniki	41

Wstęp

Współczesna piłka nożna dawno przestała być wyłącznie dyscypliną sportową i stała się jednym z najszybciej rozwijających się sektorów rozrywki. Największe kluby funkcjonują dziś jak przedsiębiorstwa o wielomilionowych budżetach, a zawodnicy stanowią ich najcenniejsze aktywa. Centralnym elementem tego ekosystemu jest rynek transferowy, na którym dochodzi do transakcji, których przedmiotem są prawa do zawodników, a kwoty pojedynczych transakcji niejednokrotnie przekraczają 100 milionów euro. Zrozumienie mechanizmów kształtujących wartość rynkową piłkarzy ma zatem istotne znaczenie nie tylko poznawcze, lecz również praktyczne – dla klubów podejmujących decyzje inwestycyjne, agentów, a także analityków obserwujących ten dynamiczny rynek.

Wycena zawodnika jest zadaniem złożonym, ponieważ na jego wartość wpływa jednocześnie wiele różnorodnych czynników – od mierzalnych statystyk sportowych, przez cechy demograficzne, aż po trudno uchwytnie zmienne marketingowe i prestiżowe. Próba ilościowego ujęcia tych zależności stanowi interesujące wyzwanie ekonometryczne, łączące teorię kapitału ludzkiego z metodami analizy regresji. To właśnie ta złożoność oraz rosnące znaczenie ekonomiczne rynku transferowego zadecydowały o wyborze tematu niniejszej pracy.

Głównym celem pracy jest identyfikacja i ocena siły wpływu czynników determinujących wartość rynkową profesjonalnych piłkarzy występujących w czołowych ligach europejskich. Realizacji tego celu służy budowa modelu ekonometrycznego, pozwalającego na ilościowe oszacowanie wpływu poszczególnych determinant przy jednoczesnej kontroli pozostałych zmiennych.

Problem badawczy pracy można sformułować w postaci pytania: które cechy zawodnika oraz jego otoczenia sportowego w największym stopniu kształtują jego wartość rynkową i w jaki sposób oddziałują na wycenę? W odpowiedzi na tak postawiony problem sformułowano trzy hipotezy badawcze:

Hipoteza pierwsza zakłada, że wiek piłkarza wpływa na jego wartość rynkową w sposób nieliniowy – młody wiek wiąże się ze znaczącą premią do wartości, która maleje wraz ze starzeniem się zawodnika.

Hipoteza druga zakłada, że prestiż ligi, w której występuje zawodnik, oraz przynależność do klubu ze światowej czołówki istotnie i dodatnio wpływają na wycenę, niezależnie od indywidualnych statystyk piłkarza.

Hipoteza trzecia zakłada, że ocena meczowa stanowi wystarczający syntetyczny wyznacznik jakości zawodnika i pozwala opierać na niej model bez istotnej utraty jego mocy

objaśniającej w stosunku do modelu opartego na tradycyjnych statystykach, takich jak liczba bramek czy asyst.

Do weryfikacji postawionych hipotez wykorzystano metodę regresji wielorakiej, estymowaną klasyczną metodą najmniejszych kwadratów. Model oparto na koncepcji cen hedonicznych, zgodnie z którą wartość dobra stanowi sumę wartości jego poszczególnych cech. Analizę przeprowadzono na bazie danych obejmującej zawodników z siedmiu najsilniejszych lig europejskich, a dane pozyskano z publicznie dostępnych zbiorów udostępnionych w serwisie Kaggle, opracowanych na podstawie wyspecjalizowanych serwisów analitycznych. Obliczenia wykonano przy użyciu pakietu ekonometrycznego Gretl.

Praca składa się z trzech rozdziałów. Rozdział pierwszy ma charakter teoretyczny i przedstawia specyfikę rynku transferowego w piłce nożnej, koncepcję kapitału ludzkiego jako fundamentu wyceny zawodników oraz przegląd determinant wartości transferowej wraz z analizą dotychczasowego stanu badań. Rozdział drugi obejmuje część metodyczną – zawiera sformułowanie celu badania i hipotez, charakterystykę próby badawczej oraz jej źródeł, konstrukcję i transformację zmiennych, a także analityczną postać modelu ekonometrycznego. Rozdział trzeci ma charakter empiryczny – przedstawia wyniki estymacji wraz z interpretacją parametrów, weryfikację diagnostyczną modelu, empiryczny obraz kluczowych determinant, pogłębioną analizę reszt i identyfikację zawodników odstających od wyceny modelowej oraz końcową weryfikację postawionych hipotez badawczych. Całość zamykają wnioski zawarte w zakończeniu.

Rozdział 1. Teoretyczne podstawy wyceny zawodników na rynku transferowym

1.1. Specyfika rynku transferowego w piłce nożnej

Rynek transferowy w profesjonalnej piłce nożnej stanowi unikalny przykład rynku pracy, który podlega odrębnym regulacjom prawnym i ekonomicznym w porównaniu z tradycyjnymi sektorami gospodarki. Kluby piłkarskie funkcjonują dziś jak przedsiębiorstwa. Piłkarze pełnią podwójną rolę. Prawnie są oni pracownikami na kontrakcie, natomiast ekonomicznie stanowią kluczowe aktywa klubu. Rynek ten jest bardzo specyficzny – piłkarze nie mogą wypowiedzieć umowy i zmienić pracodawcy w trakcie trwania kontraktu, nie ponosząc konsekwencji finansowych. Zmiana klubu w trakcie trwania kontraktu wiąże się z obowiązkiem uiszczenia przez klub nabywający zawodnika rekompensaty finansowej, zwanej kwotą odstępnego.

Współczesny kształt rynku transferowego istnieje od grudnia 1995 roku, kiedy to Europejski Trybunał Sprawiedliwości wydał wyrok w sprawie C-415/93, znany powszechnie jako „Prawo Bosmana”. Wyrok ten uregulował bardzo problematyczną relację na linii klub-zawodnik. Przed grudniem 1995 roku, nawet po wygaśnięciu umowy, kluby miały prawo żądać kwoty odstępnego za danego piłkarza. Od tamtego momentu zawodnicy, którzy wypełnią swój kontrakt są „wolnymi agentami” i nowy pracodawca może ich zatrudnić bez zapłaty odstępnego. Z tego powodu, kluby nie chcąc stracić pieniędzy, dążą do sprzedaży zawodników przed końcem ich umów, co znacząco napędza rynek i powoduje transakcje między klubami opiewające na ogromne kwoty.

Ważne w kontekście działania rynku transferowego jest to, że rynek transferowy nie funkcjonuje w sposób ciągły, lecz tylko w określonych ramach czasowych, zwanych oknem transferowym. Regulamin FIFA określa dwa okresy w roku, w których kluby mogą rejestrować nowych zawodników: przed startem sezonu latem oraz po połowie sezonu zimą.¹

Ekonomicznie zakup piłkarza przez klub to inwestycja związana z dużym ryzykiem. Na wycenę rynkową zawodników wpływa ogromna liczba czynników, od ich potencjału sportowego, po zmienne marketingowe, takie jak liczba obserwujących w mediach społecznościowych. Klub jako przedsiębiorstwo docelowo dokonuje zakupu zawodników oraz opłaca ich pensję w celu otrzymania zwrotu ze swojej inwestycji poprzez nagrody z turniejów, sprzedaż koszulek, bądź też późniejszą odsprzedaż samego zawodnika z zyskiem.

¹ FIFA, *Regulations on the Status and Transfer of Players*, FIFA, Zurich 2024, art. 6.

Ważnym elementem rynku transferowego jest Mechanizm Solidarności. Ma on na celu wsparcie klubów odpowiadających za szkolenie młodzieży. Polega na tym, że z każdego płatnego transferu odliczane jest 5% kwoty na rzecz klubów, w których piłkarz trenował między 12. a 23. rokiem życia.² Praktyczne zastosowanie tego mechanizmu widać na przykładzie transferu Roberta Lewandowskiego z Bayernu Monachium do FC Barcelony. W 2022 roku został on zakupiony przez FC Barcelonę za 45 mln euro (do 50 mln euro z bonusami). W ramach Mechanizmu Solidarności kluby, w których Lewandowski trenował między 12. a 23. rokiem życia otrzymały do podziału około 2,5 mln euro (licząc od kwoty transferu z bonusami). Dzięki temu, młodzieżowy klub MKS Varsovia Warszawa, gdzie Lewandowski trenował będąc nastolatkiem, otrzymał około 625 tys. euro.³ Suma ta dla klubu o statusie FC Barcelony jest mało istotna, natomiast dla małego klubu uczniowskiego są to znaczne środki finansowe.

W związku z zasobami ludzkimi będącymi głównymi aktywami przedsiębiorstwa, kluby piłkarskie przyjmują różne modele biznesowe w celu maksymalizacji wartości rynkowej, między innymi:

Model szkolenia (np. Borussia Dortmund, Benfica Lizbona, Ajax Amsterdam): Głównym celem jest wyszukiwanie młodych, utalentowanych zawodników z zamiarem ich rozwoju poprzez treningi na najwyższym poziomie, co znacząco podniesie ich wartość, a następnie odsprzedaż z dużym zyskiem do najbogatszych klubów.

Model kupna gwiazd (np. Real Madryt, Paris Saint-Germain): Współcześnie najbogatsze kluby mogą zdecydować się na politykę transferową polegającą na kupowaniu zawodników będących supergwiazdami za gigantyczne, nieosiągalne dla większości klubów sumy pieniędzy. Piłkarze będący supergwiazdami zwracają się bowiem nie tylko z wyników sportowych, ale także z monetyzacji ich wizerunku. Dążąc do maksymalizacji zysków najpopularniejsi zawodnicy zostają także narzędziami marketingowymi. Według A. Sznajdera, transfery najpopularniejszych zawodników są często częścią całej strategii budowania i globalizacji marki klubu.⁴

Klasycznym przykładem tej strategii jest transfer Neymara z FC Barcelony do Paris Saint-Germain w 2017 roku. Kontrolowany przez katarski kapitał klub, aktywując klauzulę odstępnego, zapłacił za Brazylijczyka 222 mln euro – kwotę ponad dwukrotnie wyższą od poprzedniego rekordu transferowego (105 mln euro za Paula Pogbę). Z perspektywy czysto

² Tamże, art. 21.

³ Klemba A., *Na transferze Lewandowskiego do Barcelony zarobią Legia i Lech, ale najwięcej Varsovia!*, Interia Sport. [online] <https://sport.interia.pl/robert-lewandowski/news-na-transferze-lewandowskiego-do-barcelony-zarobia-legia-i-lech,6160483> [dostęp: 07.07.2026].

⁴ Sznajder A., *Marketing sportu*, PWE, Warszawa 2015.

sportowej tak wysoki wydatek trudno uzasadnić oczekiwanym zwrotem z inwestycji. Transakcja stanowiła jednak element strategii budowania globalnej marki klubu oraz wzmacniania wizerunku jego właścicieli, co potwierdza marketingową logikę modelu kupna gwiazd. Transfer ten wywołał ponadto trwały efekt inflacyjny na całym rynku. Kluby, świadome, że Barcelona dysponuje świeżo pozyskanym kapitałem, żądały za swoich zawodników kwot znacznie przewyższających ich realną wartość rynkową. W rezultacie klub z Katalonii znacznie przepłacił za następców Neymara. Ousmane'a Dembélé sprowadzono z Borussii Dortmund za około 105 mln euro (z bonusami do około 140 mln), a Philippe'a Coutinho z Liverpoolu za około 120 mln euro (z bonusami do około 160 mln). Zjawisko to rozlało się następnie na kolejne segmenty rynku, podnosząc ogólny poziom cen transferowych w europejskiej piłce i pokazując, że pojedyncza transakcja największych klubów może trwale przesunąć poziom wyceny zawodników.⁵

1.2. Kapitał ludzki w analizie wyceny zawodników

Głównym fundamentem objaśniającym pochodzenie cen na rynku transferowym, jest teoria kapitału ludzkiego. Według noblisty Gary'ego Beckera kapitał ludzki to ucieleśnione w człowieku zasoby, takie jak wiedza, umiejętności, zdrowie i witalność, które zwiększają jego produktywność. Mimo tego, że teoria nie odnosi się bezpośrednio do sportu, idealnie opisuje realia ekonomiczne w piłce nożnej. Oznacza to, że szkolenie piłkarza i regularne występy w meczach analogicznie do edukacji zwiększają wartość człowieka.⁶

Wartość piłkarza na rynku transferowym jest więc równowartością zgromadzonego przez niego kapitału. Jako główne parametry wyceny piłkarza możemy potraktować jego doświadczenie oraz potencjał. Duża liczba minut rozegranych na najwyższym poziomie oraz osiągnięcia sprawiają, że piłkarz jest sprawdzony, a ryzyko przy zakupie jest niewielkie. Współcześnie jednak kluby są coraz bardziej skłonne do inwestowania największych kwot w młodych, utalentowanych piłkarzy ze znikomym doświadczeniem, licząc na uprzedzenie innych klubów w pozyskiwaniu najlepszych. W takim wypadku kapitałem zawodnika jest jego talent oraz potencjał do rozwoju, jednak inwestycja staje się bardziej ryzykowna.

Różnicę w strategii inwestycyjnej obrazuje porównanie transferów Harry'ego Kane'a (inwestycja w doświadczenie i natychmiastową jakość) oraz Mykhailo Mudryka (inwestycja w potencjał z wysokim ryzykiem).

⁵ Por. BBC Sport. *Neymar to blame for inflated transfer fees – Barcelona vice-president*. [online] <https://www.bbc.com/sport/football/42938945> [dostęp: 07.07.2026].

⁶ Becker G.S., *Human Capital: A Theoretical and Empirical Analysis, with Special Reference to Education*, Columbia University Press, New York 1964.

W przypadku Kane'a, Bayern Monachium zapłacił około 100 mln euro za 30-letniego piłkarza, który od wielu lat jest jednym z najlepszych napastników na świecie. Mimo świadomości o braku możliwości odsprzedaży 30-letniego piłkarza z zyskiem, klub zdecydował się na inwestycję w gwarancję natychmiastowych wyników sportowych.

Skrajnie odwrotnym przykładem był transfer 22-letniego Mykhailo Mudryka do angielskiego klubu Chelsea. Mimo niewielkiego doświadczenia na najwyższym poziomie europejskim, przedstawiciele Chelsea zapłacili 70 milionów euro, aby zabezpieczyć talent na przyszłość.

Rozsądniejszym podejściem do zakupu wielkiego talentu wykazał się Real Madryt, który za Endricka, brazylijskiego napastnika, zapłacił około 35 milionów euro kwoty podstawowej oraz zaoferował wysokie bonusy za przyszłe osiągnięcia zawodnika. Tym sposobem, jeżeli transfer się nie sprawdzi, klub minimalizuje ryzyko finansowe.

Wyceniając zawodników istotne jest rozróżnienie kapitału na dwie podkategorie:

Kapitał ogólny: Obejmuje umiejętności twarde takie jak szybkość, kondycja, technika. Tego rodzaju atrybuty sportowe są w przypadku piłkarza użyteczne u każdego pracodawcy i wpływają na jego wartość na rynku transferowym.

Kapitał specyficzny: Dotyczy umiejętności użytecznych tylko u aktualnego pracodawcy piłkarza, np. zgranie z partnerami z drużyny bądź znajomość taktyki obecnego trenera. Są one bezużyteczne w momencie zmiany klubu przez zawodnika i często powodują spadki formy u piłkarzy po transferze.⁷

Charakterystyczną cechą kapitału ludzkiego w piłce nożnej jest gwałtowny spadek wartości na rynku transferowym wraz z wiekiem zawodników. Początkowo wraz z rozwojem kariery, wyceny szybko rosną osiągając najwyższą wartość przeważnie między 25. a 27. rokiem życia, choć współczesny rynek coraz silniej premiuje potencjał, przez co szczyt wyceny przesuwają się w kierunku młodszych roczników. Po przekroczeniu tego wieku wartość piłkarzy regularnie się zmniejsza, często mimo utrzymania formy sportowej. Wiąże się to z malejącą perspektywą czasową na eksploatację umiejętności zawodnika oraz niższą wartością ewentualnej odsprzedaży.⁸

⁷ Tamże.

⁸ Frick B., *The Football Players' Labor Market: Empirical Evidence from the Major European Leagues*, *Scottish Journal of Political Economy* 2007, vol. 54(3), s. 422–446.

1.3. Determinanty wartości transferowej

Analiza czynników mających wpływ na wartość zawodników wymaga przyjęcia odpowiednich ram teoretycznych. Narzędziem powszechnie stosowanym w ekonometrii jest metoda cen hedonicznych, spopularyzowana przez Sherwina Rosena. Według tej metody piłkarz to zestaw cech, a jego cena rynkowa to suma ich wartości. Celem analizy jest wydobycie wartości jednostek danej cechy, np. ile warta jest jedna strzelona bramka lub wyższa średnia ocena meczowa.⁹

Determinanty wartości na podstawie badań można podzielić na trzy najważniejsze kategorie: efektywność sportową, cechy demograficzne oraz czynniki kontraktowe.

Fundamentalną determinantą wyceny są statystyki meczowe zawodnika. Historycznie używano do tego przede wszystkim liczby bramek oraz asyst, jednak ich użyteczność w ramach wyceny piłkarzy drastycznie spada w momencie analizy piłkarzy defensywnych, których wartość jest w znacznie niższym stopniu zdeterminowana przez statystyki ofensywne i udział w golach drużyny. Dlatego współczesne modele wyceny coraz bardziej polegają na ocenach algorytmicznych z meczów. Są to miary złożone które oceniają piłkarza (najczęściej w skali 1-10) sumując statystyki na boisku – od celności podań aż po wygrane pojedynki w powietrzu. Pozwala to obiektywnie porównywać wkład zawodników grających na różnych pozycjach w wynik meczu.¹⁰ Istotną determinantą wartości pozostaje również liczba rozegranych przez piłkarza minut. Regularność w dużym stopniu niweluje ryzyko związane z ewentualnym zakupem i udowadnia formę boiskową oraz fizyczną danego zawodnika. Dodatkowo jako mnożnik wartości można uwzględnić powołania piłkarzy do reprezentacji narodowej. W przypadku zawodników z krajów regularnie grających na turniejach międzynarodowych może mieć to znaczny wpływ na wartość.¹¹ Współcześnie zdarzają się sytuacje, w których kluby podpisują z piłkarzami kontrakty z klauzulą o wzroście odstępnego w wypadku powołania do kadry narodowej.

Kluczową zmienną jest wiek zawodnika. Wpływa on na wycenę w sposób nieliniowy. Młodzi i utalentowani piłkarze spotykają się z premią do ich wyceny ze względu na potencjał, natomiast starsi piłkarze, nie zważając na doświadczenie, tracą wartość przez zdecydowanie krótszy horyzont kariery. Pozycja piłkarza na boisku również jest ważna w modelach wyceny.

⁹ Rosen S., *Hedonic Prices and Implicit Markets: Product Differentiation in Pure Competition*, *Journal of Political Economy* 1974, vol. 82(1), s. 34–55.

¹⁰ Müller O., Simons A., Weinmann M., *Beyond Crowd Judgments: Data-Driven Estimation of Market Value in Association Football*, *European Journal of Operational Research* 2017, vol. 263(2), s. 611–624.

¹¹ Franck E., Nüesch S., *Talent and/or Popularity: What Does It Take to Be a Superstar?*, *Economic Inquiry* 2012, vol. 50(1), s. 202–216.

Największe wartości na rynku transferowym osiągają napastnicy, podczas gdy bramkarze wyceniani są najniżej. Jako zmienną podczas determinowania wartości piłkarza często uwzględnia się także wzrost.

1.4. Stan badań

Problematyka determinant wartości rynkowej piłkarzy doczekała się obszernej literatury empirycznej,¹² której rozwój odzwierciedla zarówno przemiany samego rynku transferowego, jak i postęp w dostępności danych. W tabeli 1 omówiono wybrane prace, najistotniejsze z punktu widzenia niniejszego badania, uporządkowane chronologicznie.

Tabela 1. Przegląd badań empirycznych nad determinantami wartości rynkowej piłkarzy

Autorzy (rok)	Dane	Metoda badania	Kluczowe wnioski
Dobson & Gerrard (1999)	Anglia, ligi zawodowe, transfery z lat 90.	Regresja kwot transferowych (KMNK)	Cena zależy od cech zawodnika oraz klubu sprzedającego i kupującego; rola siły ekonomicznej klubu i prestiżu ligi.
Frick (2007)	5 czołowych lig europejskich (przegląd wielu badań empirycznych)	Praca przeglądowa (synteza badań empirycznych)	Nieliniowy wpływ wieku na wartość; status reprezentanta kraju podnosi wycenę.
Franck & Nüesch (2012)	Bundesliga, dane meczowe i medialne: sezon 2004/2005, zawodnicy z min. 30 min gry	Regresja kwantylowa; 20 wskaźników talentu	Talent i popularność medialna niezależnie i istotnie podnoszą wartość rynkową.
Herm <i>et al.</i> (2014)	Wyceny społeczności Transfermarkt (niemiecka Bundesliga: zestawienie z realnymi transferami)	Model regresyjny dwublokowy (talent i popularność)	Wyceny społecznościowe trafnie przewidują rzeczywiste kwoty transferów.
Müller <i>et al.</i> (2017)	5 czołowych lig, 6 sezonów, N = 4217 (walidacja: 845 transferów)	Regresja wielopoziomowa; walidacja na 845 transferach	Modele oparte na szczegółowych statystykach osiągają dokładność porównywalną z wyceną tłumy.

Źródło: opracowanie własne na podstawie literatury przedmiotu.

Do prekursorskich opracowań w tym nurcie należy badanie Dobsona i Gerrarda (1999), poświęcone determinantom kwot transferowych w angielskiej piłce zawodowej lat 90. Autorzy budują ekonometryczny model regresyjny kwoty transferu, objaśniając ją zarówno cechami samego zawodnika (wiek, pozycja, status reprezentanta, liczba występów i strzelonych bramek), jak i charakterystykami klubu sprzedającego oraz kupującego. Kluczowym wnioskiem jest spostrzeżenie, że cena zawodnika zależy nie tylko od jego jakości, lecz także

¹² Zob. m.in. Carmichael F., Forrest D., Simmons R., The Labour Market in Association Football: Who Gets Transferred and For How Much?, *Bulletin of Economic Research* 1999, vol. 51(2), s. 125–150.

od nabywcy – przy pozostałych warunkach niezmiennych bogatszy i większy klub musi zapłacić więcej, co dowodzi wpływu siły ekonomicznej klubów oraz prestiżu rozgrywek na poziom cen. Autorzy zwracają również uwagę, że po wyroku Bosmana istotnym czynnikiem ceny stał się czas pozostały do wygaśnięcia kontraktu. Badanie objęło transfery z czterech angielskich lig zawodowych w latach 90. XX wieku.

Obszerne podsumowanie dorobku tego obszaru przedstawia praca przeglądowa Fricka (2007), obejmująca pięć czołowych lig europejskich. Autor dokonuje przeglądu dostępnych dowodów empirycznych dotyczących czterech wymiarów rynku pracy piłkarzy – wynagrodzeń, transferów, kontraktów oraz mobilności zawodników – wskazując zarazem kierunki dalszych badań. Z zebranych analiz wyłania się kilka prawidłowości istotnych dla niniejszej pracy: wiek zawodnika oddziałuje na jego wartość w sposób nieliniowy (wartość maleje wraz z wiekiem wskutek spadku możliwości fizycznych), a doświadczenie oraz status reprezentanta kraju (liczba występów w kadrze narodowej) istotnie podnoszą wycenę. Frick dokumentuje także skokowy wpływ wyroku Bosmana na poziom kwot transferowych.

Odrębny nurt badań koncentruje się na źródłach statusu supergwiazdy i roli czynników pozasportowych. Franck i Nüesch (2012), analizując zawodników niemieckiej Bundesligi, podejmują klasyczny spór o to, czy o wartości gwiazdy decyduje talent (w ujęciu Rosena), czy popularność (w ujęciu Adlera). Ze względu na trudność bezpośredniego pomiaru talentu autorzy szacują go na podstawie aż dwudziestu wskaźników efektywności, ujmujących wkład zawodnika we wzrost prawdopodobieństwa zwycięstwa drużyny, popularność zaś mierzą obecnością medialną; wykorzystują przy tym regresję kwantylową. Wynik jest jednoznaczny – zarówno talent jak i popularność istotnie oraz niezależnie podnoszą wartość rynkową zawodnika. Potencjał marketingowy stanowi zatem samodzielną determinantę wyceny, uzupełniającą czysto sportową jakość. Próbę badawczą stanowili wszyscy zawodnicy Bundesligi z sezonu 2004/2005, którzy rozegrali w nim co najmniej pół godziny.

Wraz z upowszechnieniem serwisu Transfermarkt przedmiotem badań stała się wiarygodność wycen tworzonych przez internetową społeczność (tzw. mądrość tłumu). Herm, Callsen-Bracker i Kreis (2014) analizują, jak społeczność ta wycenia piłkarzy i porównują jej szacunki z rzeczywistymi kwotami transferów. Wyceny społecznościowe okazują się znakomitymi predyktorami faktycznych kwot transferowych, a same oceny dają się w dużej mierze odtworzyć modelem ekonometrycznym opartym na dwóch blokach zmiennych – miarach związanych bezpośrednio z talentem zawodnika oraz zmiennych odzwierciedlających jego popularność i rozpoznawalność. Ustalenie to ma znaczenie metodologiczne: uzasadnia powszechne wykorzystywanie wycen z Transfermarktu jako rzetelnego przybliżenia realnej

wartości rynkowej w badaniach naukowych. Analizę przeprowadzono na danych dotyczących piłkarzy niemieckiej Bundesligi, zestawiając wyceny społeczności z rzeczywistymi kwotami transferów.

Najbliższe metodologicznie niniejszej pracy jest badanie Müllera, Simonsa i Weinmanna (2017), w którym autorzy konstruują „oparty na danych” model wyceny, mający stanowić alternatywę dla wycen społecznościowych. Na unikalnym zbiorze obejmującym 4217 zawodników z pięciu czołowych lig europejskich w okresie sześciu sezonów szacują oni wartość rynkową za pomocą regresji wielopoziomowej, kwantyfikując wpływ ponad dwudziestu wskaźników, a trafność modelu weryfikują porównaniem z 845 rzeczywistymi kwotami transferów oraz z wycenami społeczności. Wykazują, że modele oparte na szczegółowych statystykach pozwalają uzyskać dokładność porównywalną z wyceną tłumu, przy zachowaniu obiektywności, powtarzalności i możliwości bieżącej aktualizacji. Praca ta uzasadnia podejście przyjęte w niniejszym opracowaniu – modelowanie wartości rynkowej na podstawie obiektywnych, mierzalnych cech zawodnika.

Przedstawione badania wyznaczają ramy teoretyczne i metodyczne dla niniejszej pracy. Z jednej strony potwierdzają zestaw kluczowych determinant – wiek, jakość sportową, status klubu oraz prestiż ligi – z drugiej zaś wskazują na rosnące znaczenie syntetycznych, opartych na danych miar jakości, do których nawiązuje przyjęta tu ocena meczowa.

Rozdział 2. Metodyka badania i charakterystyka danych

2.1. Cel i hipotezy badawcze

Celem pracy jest identyfikacja i pomiar siły oddziaływania czynników determinujących wartość rynkową profesjonalnych piłkarzy występujących w czołowych ligach europejskich. Badanie ma zweryfikować stopień wpływu statystyk sportowych, cech demograficznych oraz prestiżu klubu i ligi na wycenę rynkową zawodnika. Niniejszy rozdział przedstawia metodykę badania oraz charakterystykę danych wykorzystanych w analizie empirycznej.

W analizie przyjęto perspektywę metody cen hedonicznych, zgodnie z którą cena dobra stanowi sumę wartości jego poszczególnych cech, a celem estymacji jest wyodrębnienie krańcowego wpływu każdej z nich na wartość rynkową zawodnika.¹³

Na potrzeby badania sformułowano następujące hipotezy badawcze:

- Hipoteza 1. Wiek piłkarza ma nieliniowy wpływ na jego wartość rynkową. Młody wiek wiąże się ze znaczącą premią do wartości, która spada wraz ze starzeniem się zawodnika.
- Hipoteza 2. Prestiż ligi, w której występuje zawodnik, oraz przynależność do klubu ze światowej czołówki istotnie dodatnio wpływają na wycenę, niezależnie od statystyk piłkarza.
- Hipoteza 3. Ocena meczowa (zmienna „rating”) jest wystarczającym wyznacznikiem jakości zawodnika i pozwala oprzeć na niej specyfikację modelu. Współczynnik determinacji nie spada wyraźnie w stosunku do modelu ze zmiennymi takimi jak gole, asysty czy odbiory.

2.2. Charakterystyka próby i źródeł danych

Badanie zostało przeprowadzone na bazie danych obejmującej ostatecznie, po opisanej dalej selekcji próby, 2006 zawodników z najlepszych siedmiu lig europejskich według rankingu UEFA.¹⁴ Zmienną objaśnianą jest wartość rynkowa zawodnika wyrażona w euro. Dane wykorzystane w badaniu pochodzą z dwóch publicznie dostępnych zbiorów udostępnionych w serwisie Kaggle. Podstawowym źródłem był zbiór opracowany przez K. Yorguna,¹⁵ obejmujący zawodników z czołowych lig europejskich, z którego zaczerpnięto wartość rynkową zawodnika

¹³ Rosen S., dz. cyt.

¹⁴ UEFA, *Country coefficients*, <https://www.uefa.com/nationalassociations/uefarankings/country/> [dostęp: 07.07.2026].

¹⁵ Yorgun K., *European Top Leagues Player Stats 25-26* [zbiór danych], Kaggle, <https://www.kaggle.com/datasets/kaanyorgun/european-top-leagues-player-stats-25-26> [dostęp: 07.07.2026].


(zmienną objaśnianą), syntetyczną ocenę meczową (rating) oraz statystyki boiskowe. Zarówno wartości rynkowe, jak i oceny meczowe pochodzą z serwisu SofaScore, przy czym publikowane przez ten serwis wyceny mają charakter analogiczny do szacunków społeczności analizowanych przez Herm i in. (2014), ponieważ serwis umożliwia użytkownikom ocenę trafności wyceny (głosowanie, czy wartość zawodnika jest zawyżona bądź zaniżona), łącząc tym samym podejście algorytmiczne z mądrością tłumu, i stanowią rzetelne przybliżenie realnej wartości rynkowej. Zbiór ten uzupełniono szczegółowymi danymi statystycznymi pochodzącymi ze zbioru opracowanego przez H. Sidorowicza na podstawie serwisu FBref.¹⁶ Z wykorzystanych źródeł zaczerpnięto również informacje o klubie, pozycji, narodowości oraz wieku zawodnika. Zgromadzone dane mają charakter przekrojowy i odzwierciedlają stan z przełomu kwietnia i maja 2026 roku, obejmując tym samym przeważającą część sezonu 2025/26.

Istotne w procesie przygotowywania bazy danych było wyselekcjonowanie i odpowiednie oczyszczenie próby. Zdecydowano się na odrzucenie z badania zawodników, którzy w trakcie analizowanego okresu rozegrali poniżej 600 minut ligowych. Zabieg ten miał na celu wykluczenie graczy rezerwowych, zawodników z drużyn młodzieżowych grających jedynie końcówki meczów oraz innych graczy potencjalnie zaburzających model. Ich wycena może być oparta na spekulacjach bądź wynikach z poprzednich sezonów, natomiast ich statystyki – m.in. ocena meczowa – mogą być niemiarodajne z powodu bardzo małej liczby obserwacji.

Ostateczny zbiór danych powstał z połączenia dwóch źródeł. Podstawowy zbiór obejmujący wszystkie siedem analizowanych lig, zawierał wartości rynkowe, oceny meczowe oraz statystyki zawodników, nie zawierał jednak kompletnej informacji o wieku – ta dostępna była w drugim zbiorze, opartym na serwisie FBref, wyłącznie dla pięciu czołowych lig. Dla zawodników z Eredivisie oraz Ligi Portugal wiek uzupełniono zatem odrębnie, tak aby zmienna obejmowała pełną próbę. Szczególnej uwagi wymagała zmienna pozycji zawodnika. W danych źródłowych przypisanie pozycji opierało się na pojedynczym, uproszczonym oznaczeniu, co prowadziło do błędów – zawodnicy ofensywni grający na skrzydłach bywali klasyfikowani jako pomocnicy, co zaniżałoby szacowaną premię napastników. Pozycje przypisano zatem ponownie, na podstawie pełnego oznaczenia pozycyjnego z serwisu FBref, według przejrzystej reguły: każde oznaczenie napastnika (również w wariacie łączonym, np. pomocnik-napastnik)

¹⁶ Sidorowicz H., *Football Players Stats (2025–2026)* [zbiór danych], Kaggle, <https://www.kaggle.com/datasets/hubertsidorowicz/football-players-stats-2025-2026> [dostęp: 07.07.2026].

klasyfikowano jako napastnika, czyste oznaczenie pomocnika – jako pomocnika, a obrońcę – jako obrońcę; bramkarzy z próby wykluczono. Korekta ta objęła 168 zawodników (m.in. L. Yamala i Raphinhę, przekwalifikowanych z pomocników na napastników). Zebrano również informację o narodowości zawodnika. Na jej podstawie skonstruowano dodatkową zmienną zero-jedynkową (*top_nation*), przyjmującą wartość 1 dla zawodników pochodzących z państw należących do piłkarskiej czołówki (m.in. Hiszpanii, Anglii, Brazylii czy Francji) oraz 0 dla pozostałych. Zmienna ta okazała się jednak statystycznie nieistotna, dlatego ostatecznie nie włączono jej do końcowej specyfikacji modelu. Wynik ten należy wiązać ze sposobem doboru próby. Analiza obejmuje wyłącznie siedem najsilniejszych lig europejskich, a więc zawodników już mocno wyselekcjonowanych pod względem poziomu sportowego. W tak zawężonym zbiorze zmienna opisująca pochodzenie wykazuje zbyt małe zróżnicowanie, by jej wpływ był statystycznie wykrywalny. Nie oznacza to, że pochodzenie zawodnika nie ma znaczenia dla wyceny w ogóle. Jego ewentualny efekt mógłby ujawnić się dopiero w próbie obejmującej szersze spektrum lig i poziomów rozgrywkowych. Po przeprowadzeniu opisanych korekt oraz omówionym wyżej oczyszczeniu próby ostateczny zbiór analityczny objął 2006 zawodników z pola, należących do siedmiu lig europejskich.




Rysunek 1. Rozkład wartości rynkowej zawodników w próbie badawczej (przed transformacją logarytmiczną).

Źródło: opracowanie własne na podstawie zbiorów danych z platformy Kaggle (dane pierwotne: SofaScore i FBref).

2.3. Konstrukcja i transformacja zmiennych

Ze względu na prawostronną asymetrię rozkładu cen piłkarzy (nieliczni piłkarze osiągają bardzo wysokie ceny, podczas gdy większość jest warta zdecydowanie mniej) zdecydowano się na zastosowanie logarytmu naturalnego dla zmiennej objaśnianej oraz liczby rozegranych minut. Silną prawostronną asymetrię rozkładu wartości rynkowej przed transformacją przedstawia rysunek 1. Po zlogarytmowaniu rozkład staje się zbliżony do symetrycznego, co ilustruje rysunek 2.¹⁷



Rysunek 2. Rozkład logarytmu naturalnego wartości rynkowej zawodników.

Źródło: opracowanie własne na podstawie zbiorów danych z platformy Kaggle (dane pierwotne: SofaScore i FBref).

Pozwala to zmienić sposób interpretacji oszacowanych parametrów. Współczynniki przy zmiennych objaśniających informują o przyrostach procentowych zamiast sztywnych kwot i lepiej odzwierciedlają specyfikę rynku transferowego. Zastosowanie logarytmu dla

¹⁷ Zob. Maddala G. S., *Ekonometria*, Wydawnictwo Naukowe PWN, Warszawa 2006.

liczby rozegranych minut pozwala ująć zjawisko malejących przychodów krańcowych. Różnica między piłkarzem mającym 600 a 1200 rozegranych minut jest ogromna. Pierwszy będzie rezerwowym o marginalnej roli w zespole, natomiast drugi będzie zawodnikiem regularnej rotacji. Między graczami mającymi np. 2400 i 3000 rozegranych minut różnica jest znacznie mniej istotna, ponieważ obaj będą kluczowymi zawodnikami swojej drużyny, a różnica będzie wynikać z głębi składu bądź krótkiej kontuzji. Zastosowanie logarytmów sprawia, że model analizuje czas gry w ujęciu procentowym. Unika się więc błędnego założenia, że każda rozegrana minuta zmienia wartość piłkarza o taką samą kwotę.

Kluczowe dla modelu było ujęcie starzenia się sportowca. Z tego względu jako predyktorów wprowadzono zmienną wieku (*age_new*) oraz jej kwadrat (*sq_age_new*). Nieliniowa postać funkcyjna ma na celu odzwierciedlenie paraboli wpływu wieku na wartość.¹⁸ Mechanizm ten zakłada, że rynek transferowy najbardziej ceni potencjał zawodnika i przyznaje najwyższą premię młodym graczom, natomiast po przekroczeniu matematycznego szczytu formy premia do wyceny zaczyna zanikać, niezależnie od statystyk meczowych.

Do oceny jakości piłkarskiej badanych zawodników zdecydowano się na wykorzystanie średniej oceny meczowej (*rating*) z serwisu SofaScore. Jest to najbardziej uniwersalny parametr mogący skutecznie zastąpić tradycyjne statystyki, takie jak gole lub asysty, oraz niwelujący dyskryminację zawodników ze względu na ich pozycję – tzn. jest inaczej liczony dla napastników i obrońców i pozwala sprawiedliwie wycenić graczy formacji defensywnych, którzy bywają niedoszacowani np. ze względu na mniejszą liczbę bramek oraz znikome statystyki ofensywne.

Ważnym elementem specyfikacji modelu ekonometrycznego było wprowadzenie zmiennych zero-jedynkowych. Prestiż marki klubu czy poziom rozgrywek, w których piłkarz występuje, silnie determinują wycenę rynkową.

Pierwszą wprowadzoną zmienną jakościową jest „*top_club*”. Przyjmuje ona wartość 1 u zawodników występujących w klubach będących sportową i finansową elitą europejską oraz wartość 0 u całej reszty próby. Wykaz klubów zaliczonych do tej kategorii zamieszczono w załączniku 5. Zmienna wyłapuje „premię wizerunkową”, weryfikując, czy sama przynależność do klubu będącego globalnym gigantem zwiększa wartość zawodnika niezależnie od jego jakości na boisku.

Uwzględnione zostały również zmienne zróżnicowania poziomu rozgrywek, w których występują analizowani piłkarze. Zróżnicowanie ujęto za pomocą zmiennych jakościowych

¹⁸ Frick B., dz. cyt.

oznaczonych od Dleague_1 do Dleague_6. W celu uniknięcia współliniowości zmiennych objaśniających celowo usunięto zmienną przypisaną do Premier League.¹⁹ Pełni ona funkcję grupy bazowej, do której odnoszą się zmienne przypisane do pozostałych sześciu lig.

2.4. Statystyki opisowe próby

Przed przystąpieniem do estymacji parametrów strukturalnych modelu dokonano wstępnej analizy rozkładu empirycznego zgromadzonych danych. Analiza statystyk opisowych dla 2006 obserwacji pozwoliła na lepsze zrozumienie struktury badanej populacji. Średnia wartość rynkowa zawodnika w analizowanej próbie wyniosła 14,04 mln euro, przy medianie wynoszącej zaledwie 6,40 mln euro oraz niezwykle wysokim odchyleniu standardowym na poziomie 20,11 mln euro. Ponad dwukrotnie wyższa wartość średniej względem mediany jednoznacznie potwierdza prawostronną asymetrię rozkładu i słuszność zastosowania transformacji logarytmicznej. Średni wiek badanego piłkarza to 26,13 lat (odchylenie standardowe to 4,10), co odpowiada okresowi przeważnie utożsamianemu ze szczytem kariery sportowej. Z kolei średnia nota meczowa wyniosła 6,81 (odchylenie standardowe to zaledwie 0,22, przy zakresie od 6,04 do 8,00). Tak niewielki rozrzut oznacza, że oceny meczowe są silnie skoncentrowane wokół średniej, a nawet niewielkie różnice w ocenie skutecznie różnicują zawodników pod względem postrzeganej jakości.

Podstawowe statystyki opisowe zmiennych ilościowych zestawiono w tabeli 2.

Tabela 2. Statystyki opisowe zmiennych ilościowych (N = 2006)

Zmienna	Średnia	Mediana	Odch. std.	Minimum	Maksimum
Wartość rynkowa (mln euro)	14,04	6,40	20,11	0,05	218,00
Ocena meczowa (rating)	6,81	6,79	0,22	6,04	8,00
Rozebrane minuty	1566	1528	604	600	2970
Wiek (lata)	26,13	26,00	4,10	18,00	42,00

Źródło: opracowanie własne na podstawie zbiorów danych z platformy Kaggle (dane pierwotne: SofaScore i FBref).

Uzupełnieniem powyższego zestawienia są zmienne jakościowe. Zmienna `top_club` przyjmuje wartość 1 dla 392 zawodników, co stanowi 19,5% próby, reprezentujących kluby zaliczane do europejskiej elity sportowej i finansowej. Zmienne ligowe (`Dleague_1` – `Dleague_6`) opisują przynależność zawodnika do jednej z sześciu lig, podczas gdy kategorię bazową stanowi Premier League.

¹⁹ Maddala G. S., dz. cyt.

2.5. Postać analityczna modelu

Ostateczna postać analityczna skonstruowanego modelu ekonometrycznego, mającego na celu weryfikację postawionych hipotez, przedstawia równanie (1).

$$\begin{aligned} \ln(\text{market_value})_i = & \beta_0 + \beta_1 \text{Dleague_1}_i + \beta_2 \text{Dleague_2}_i + \beta_3 \text{Dleague_3}_i + \\ & \beta_4 \text{Dleague_4}_i + \beta_5 \text{Dleague_5}_i + \beta_6 \text{Dleague_6}_i + \beta_7 \text{top_club}_i + \beta_8 \text{rating}_i + \\ & \beta_9 \ln(\text{minutes_played})_i + \beta_{10} \text{age_new}_i + \beta_{11} \text{age_new}_i^2 + \beta_{12} \text{Dpos_fbref_1}_i + \\ & \beta_{13} \text{Dpos_fbref_2}_i + \epsilon_i \end{aligned} \quad (1)$$

gdzie:

$\ln(\text{market_value})_i$ - zmienna objaśniana, logarytm naturalny wartości rynkowej i-tego zawodnika,

β_0 – wyraz wolny modelu

$\beta_1, \dots, \beta_{13}$ – parametry strukturalne, opisujące kierunek i siłę wpływu poszczególnych zmiennych objaśniających,

Dleague_1_i – zmienna zero-jedynkowa równa 1, gdy zawodnik występuje w Eredivisie, oraz 0 w przeciwnym przypadku,

Dleague_2_i – zmienna zero-jedynkowa dla La Liga,

Dleague_3_i – zmienna zero-jedynkowa dla Bundesligi,

Dleague_4_i – zmienna zero-jedynkowa dla Serie A,

Dleague_5_i – zmienna zero-jedynkowa dla Ligue 1,

Dleague_6_i – zmienna zero-jedynkowa dla Ligi Portugal (kategoria bazowa dla zmiennych ligowych: Premier League),

top_club_i – zmienna zero-jedynkowa równa 1, gdy zawodnik występuje w klubie zaliczonym do europejskiej elity finansowo-sportowej, oraz 0 w przeciwnym przypadku,

rating_i – średnia ocena meczowa i-tego zawodnika,

$\ln(\text{minutes_played})_i$ – logarytm naturalny liczby rozegranych minut ligowych,

age_new_i – wiek zawodnika (w latach),

age_new_i^2 – kwadrat wieku zawodnika,

Dpos_fbref_1_i – zmienna zero-jedynkowa równa 1 dla pomocnika, oraz 0 w przeciwnym przypadku,

$Dpos_fbref_2_i$ – zmienna zero-jedynkowa równa 1 dla napastnika, oraz 0 w przeciwnym przypadku (kategoria bazowa dla zmiennych pozycji: obrońca),

ϵ_i – składnik losowy modelu,

i – numer zawodnika ($i = 1, 2, \dots, 2006$).

Parametry strukturalne oszacowano klasyczną metodą najmniejszych kwadratów (KMNK). Poprawność oszacowanego modelu zweryfikowano za pomocą zestawu testów diagnostycznych. Test White'a posłużył do zbadania homoskedastyczności składnika losowego. W przypadku odrzucenia hipotezy o homoskedastyczności wnioskowanie oparto na odpornych błędach standardowych. Normalność rozkładu reszt zbadano testem Doornika-Hansena, weryfikującym łącznie skośność i kurtozę rozkładu. Poprawność przyjętej formy funkcyjnej oceniono testem RESET Ramsey'a, natomiast skalę współliniowości zmiennych objaśniających – za pomocą czynników inflacji wariancji (VIF).

Rozdział 3. Wyniki badań empirycznych

3.1. Wyniki estymacji i interpretacja parametrów modelu

Estymacji klasyczną metodą najmniejszych kwadratów (KMNK) poddano model log liniowy opisany w rozdziale 2. Z uwagi na wykrytą heteroskedastyczność składnika losowego – potwierdzoną testem White’a – do prezentowanych wyników zastosowano odporne błędy standardowe w wariancie HC1 (*ang. heteroskedasticity-consistent standard errors*).²⁰ Zapewnia to poprawność wnioskowania statystycznego mimo naruszenia założenia o stałości wariancji reszt. Wyniki estymacji dla 2006 obserwacji przedstawia tabela 3.

Tabela 3. Wyniki estymacji modelu log-liniowego (błędy standardowe HC1)

Zmienna	Współczynnik	Błąd std. (HC1)	Statystyka t
wyraz wolny (const)	-0,763847	0,911856	-0,8377
Dleague_1 (Eredivisie)	-2,29850***	0,0672052	-34,20
Dleague_2 (La Liga)	-0,995081***	0,0481036	-20,69
Dleague_3 (Bundesliga)	-0,898751***	0,0460646	-19,51
Dleague_4 (Serie A)	-0,865819***	0,0467222	-18,53
Dleague_5 (Ligue 1)	-1,05630***	0,0539566	-19,58
Dleague_6 (Liga Portugal)	-2,15978***	0,0745336	-28,98
top_club	0,935392***	0,0391506	23,89
rating	1,96577***	0,0914865	21,49
l_minutes_played	0,404818***	0,0489805	8,265
age_new	0,191885***	0,0537805	3,568
sq_age_new	-0,00590146***	0,000985705	-5,987
Dpos_fbref_1 (pomocnik)	0,0329485	0,0403966	0,8156
Dpos_fbref_2 (napastnik)	0,351150***	0,0461156	7,615

Uwaga: *** oznacza istotność na poziomie 1%. Zmienna bazowa dla lig: Premier League (Anglia) $R^2 = 0,714514$; skorygowane $R^2 = 0,712651$; błąd standardowy reszt = 0,774280.

Źródło: opracowanie własne na podstawie zbiorów danych z platformy Kaggle (dane pierwotne: SofaScore i FBref).

Model wykazuje wysokie dopasowanie do danych – współczynnik determinacji wynosi 0,7145, co oznacza, że uwzględnione zmienne wyjaśniają 71,45% zmienności logarytmu wartości rynkowej piłkarzy. Wszystkie zmienne objaśniające, z wyjątkiem zmiennej

²⁰ MacKinnon J. G., White H., *Some Heteroskedasticity-Consistent Covariance Matrix Estimators with Improved Finite Sample Properties*, *Journal of Econometrics* 1985, vol. 29(3), s. 305–325.

Dpos_fbref_1 oznaczającej pomocników, są istotne statystycznie na poziomie 1%. Nieistotny statystycznie okazał się również wyraz wolny, który jednak jako parametr techniczny nie podlega interpretacji ekonomicznej. Pełny wydruk wyników estymacji z programu gretl zamieszczono w załączniku 1.

Ocena meczowa (rating)

Zmienna rating okazała się najsilniejszym predyktorem wartości rynkowej. Jej współczynnik wynosi 1,96577. Z uwagi na dużą wartość parametru interpretacja wymaga zastosowania dokładnego przekształcenia dla modelu log-liniowego: wzrost średniej oceny meczowej o jeden pełny punkt odpowiada wzrostowi wartości rynkowej o około 614% ($e^{1,96577} - 1 \approx 6,14$). Należy jednak podkreślić, że wzrost ratingu o cały punkt znacznie wykracza poza realny zakres zmienności tej zmiennej w próbie – odchylenie standardowe oceny meczowej wynosi zaledwie 0,22, a cały zakres mieści się w przedziale od 6,04 do 8,00. Bardziej miarodajna jest zatem interpretacja w odniesieniu do realistycznej zmiany: wzrost oceny meczowej o 0,1 punktu przekłada się na wzrost wartości rynkowej o około 21,7% ($e^{0,196577} - 1 \approx 0,217$). Tak silny efekt jest spójny z hipotezą 3 – ocena meczowa stanowi wystarczający syntetyczny wyznacznik jakości zawodnika, skutecznie zastępując tradycyjne statystyki takie jak liczba goli, asyst czy odbiorów, które dla różnych pozycji mają odmienną wagę i interpretację.

Czas gry (l_minutes_played)

Logarytm liczby rozegranych minut (l_minutes_played) wpływa istotnie i dodatnio na wartość rynkową. Ponieważ zarówno zmienna objaśniana, jak i objaśniająca występują w postaci logarytmicznej, współczynnik 0,404818 należy interpretować jako elastyczność – wzrost liczby rozegranych minut o 1% przekłada się na wzrost wartości rynkowej o około 0,40%. Wynik ten potwierdza ekonomiczną intuicję – regularność gry jest sygnałem zaufania trenera i klubu, który rynek transferowy wycenia pozytywnie. Zastosowanie postaci logarytmicznej pozwala uchwycić malejące przychody krańcowe z kolejnych minut gry, zgodnie z założeniami opisanymi w rozdziale 2.

Wiek zawodnika (age_new, sq_age_new)

Para zmiennych age_new i sq_age_new modeluje nieliniowy wpływ wieku na wartość rynkową. Dodatni współczynnik przy zmiennej liniowej (0,191885) oraz ujemny przy kwadracie (-0,00590146) wskazują na zależność paraboliczną o ramionach skierowanych w dół. Matematyczny wierzchołek funkcji przypada na wiek około 16,3 roku życia ($-0,191885 / (2 * (-0,00590146)) \approx 16,3$), a więc poniżej minimalnego wieku zawodnika w próbie, który wynosi 18 lat. Oznacza to, że w całym obserwowanym zakresie danych (18–42 lata) wartość


rynkowa maleje wraz z wiekiem w sposób monotoniczny – dodatni człon liniowy nie świadczy o realnym wzroście wartości u dorosłych zawodników, lecz jest konsekwencją dopasowania paraboli do danych zawierających wyjątkowo wysoko wycenianych juniorów (m.in. L. Yamal, F. Cubarsí). Należy przy tym odróżnić ten warunkowy (*ceteris paribus*) efekt wieku, oszacowany po uwzględnieniu pozostałych zmiennych modelu, od surowej zależności dwuwymiarowej przedstawionej na rysunku 3. W ujęciu dwuwymiarowym, bez kontroli oceny meczowej, liczby rozegranych minut, ligi, przynależności do czołowego klubu oraz pozycji, wartość rynkowa utrzymuje się na najwyższym poziomie u zawodników do 26. roku życia, a następnie systematycznie maleje (dopasowana funkcja kwadratowa osiąga maksimum około 22. roku życia, jednak jej przebieg w okolicy szczytu jest płaski, a mediany wartości utrzymują się na wysokim, zbliżonym poziomie w przedziałach od 21 do 26 lat, por. tabela 5). Wierzchołek modelu wypada znacznie niżej (około 16 lat), ponieważ model mierzy wpływ samego wieku przy stałych pozostałych zmiennych, podczas gdy w ujęciu surowym z wiekiem mieszają się skorelowane z nim cechy, takie jak regularność gry czy poziom rozgrywek. Tempo spadku rośnie z wiekiem: w okolicy średniego wieku w próbie (26 lat) krańcowy spadek wynosi około 10,9% wartości rynkowej na każdy dodatkowy rok ($e^{-0,115} - 1$). Oba parametry są istotne statystycznie na poziomie 1%, potwierdzając hipotezę 1 o nieliniowym wpływie wieku na wartość rynkową.²¹

Przynależność do czołowego klubu (*top_club*)

Zmienna zero-jedynkowa *top_club* przyjmuje wartość 1 dla zawodników występujących w klubach należących do europejskiej finansowej i sportowej elity. Jej współczynnik wynosi 0,935392, co oznacza, że – przy pozostałych czynnikach niezmiennych – przynależność do czołowego klubu przekłada się na wzrost wartości rynkowej o około 155% w porównaniu z piłkarzami z pozostałych drużyn ($e^{0,935392} - 1 \approx 1,548$). Wynik ten potwierdza hipotezę 2 i świadczy o istnieniu silnej premii wizerunkowej – sama marka klubu istotnie wpływa na wycenę zawodnika niezależnie od jego indywidualnych statystyk.²² Mechanizm ten jest spójny z badaniami wskazującymi, że obok talentu na wartość rynkową zawodnika oddziałuje również jego popularność i siła marketingowa.

²¹ Frick B., dz. cyt.

²² Franck E., Nüesch S., dz. cyt.



Rysunek 3. Zależność logarytmu wartości rynkowej od wieku zawodnika wraz z dopasowaną funkcją kwadratową.

Źródło: opracowanie własne na podstawie zbiorów danych z platformy Kaggle (dane pierwotne: SofaScore i FBref).


Zmienne ligowe (Dleague_1 – Dleague_6)

Wszystkie zmienne ligowe są istotne statystycznie i ujemne, co oznacza, że zawodnicy z każdej analizowanej ligi są wyceniani niżej niż piłkarze z Premier League (kategoria bazowa). Wyniki wskazują na wyraźną hierarchię ligową na europejskim rynku transferowym.

Największe dyskonto w stosunku do Premier League odnotowują zawodnicy z Eredivisie (współczynnik -2,29850, co odpowiada niższej wartości o około 90,0%) oraz Ligi Portugal (współczynnik -2,15978, dyskonto około 88,5%). Pozostałe ligi (La Liga, Bundesliga, Serie A i Ligue 1) wykazują pośrednie poziomy dyskonta. Wyniki te potwierdzają hipotezę 2 – prestiż ligi jest istotną, niezależną determinantą wartości rynkowej piłkarza, co odpowiada wcześniejszym ustaleniom wskazującym na rolę siły ekonomicznej rozgrywek i klubów w kształtowaniu cen transferowych.²³

²³Dobson S., Gerrard B., *The Determination of Player Transfer Fees in English Professional Soccer*, *Journal of Sport Management* 1999, vol. 13(4), s. 259–279.

Zróźnicowanie wartości rynkowej pomiędzy ligami obrazują wykresy pudełkowe na rysunku 4.



Rysunek 4. Rozkład wartości rynkowej zawodników według ligi (wykresy pudełkowe).

Źródło: opracowanie własne na podstawie zbiorów danych z platformy Kaggle (dane pierwotne: SofaScore i FBref).

3.2. Walidacja modelu

Po estymacji parametrów strukturalnych przeprowadzono szereg testów diagnostycznych w celu oceny poprawności specyfikacji modelu oraz spełnienia założeń klasycznej metody najmniejszych kwadratów. Wyniki testów zestawiono w tabeli 4.

Tabela 4. Wyniki testów diagnostycznych modelu

Test	Statystyka	Wartość p	Decyzja ($\alpha = 0,05$)
White'a (heteroskedastyczność)	$TR^2 = 297,10; \chi^2(16)$	0,0000	odrzucenie H_0
Doornika-Hansena (normalność reszt)	$\chi^2(2) = 67,41$	0,0000	odrzucenie H_0
RESET Ramseya (specyfikacja)	$F(2, 1990) = 23,47$	$8,4 \cdot 10^{-11}$	odrzucenie H_0

Źródło: opracowanie własne na podstawie zbiorów danych z platformy Kaggle (dane pierwotne: SofaScore i FBref).

Test White'a na heteroskedastyczność

W celu weryfikacji założenia o homoskedastyczności składnika losowego przeprowadzono test White'a²⁴ w wersji z samymi kwadratami zmiennych objaśniających. Statystyka testu wyniosła $TR^2 = 297,10$ i podlega rozkładowi chi-kwadrat z 16 stopniami swobody. Wartość p równa 0,0000 oznacza odrzucenie hipotezy zerowej o stałości wariancji składnika losowego na każdym konwencjonalnym poziomie istotności. Stwierdzenie heteroskedastyczności jest zjawiskiem typowym dla przekrojowych danych dotyczących indywidualnych wartości rynkowych – rozrzut wycen jest naturalnie większy wśród zawodników z wyższej półki. W odpowiedzi na wykrytą heteroskedastyczność wszystkie prezentowane wyniki opierają się na odpornych błędach standardowych w wariancie HC1, co zapewnia ważność przeprowadzonego wnioskowania statystycznego bez konieczności zmiany metody estymacji.

Test Doornika-Hansena na normalność rozkładu reszt


Normalność rozkładu reszt zbadano testem Doornika-Hansena²⁵, który weryfikuje jednocześnie skośność i kurtozę empirycznego rozkładu reszt. Statystyka testu chi-kwadrat(2) = 67,41 z wartością p równą 0,0000 prowadzi do odrzucenia hipotezy zerowej o normalności. Wynik ten jest typowy dla dużych prób – przy $n = 2006$ obserwacji nawet drobne odchylenia od normalności skutkują odrzuceniem hipotezy zerowej. Wykres rozkładu reszt wskazuje jednak na kształt zbliżony do normalnego, bez wyraźnej asymetrii ani grubych ogonów. Co więcej, przy tak licznej próbie wnioskowanie statystyczne opiera się na centralnym twierdzeniu granicznym, które gwarantuje asymptotyczną normalność rozkładu estymatora KMNK niezależnie od rozkładu składnika losowego.²⁶ Odrzucenie normalności reszt nie podważa zatem ważności uzyskanych wyników.

²⁴ White H., *A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity*, *Econometrica* 1980, vol. 48(4), s. 817–838.

²⁵ Doornik J.A., Hansen H., *An Omnibus Test for Univariate and Multivariate Normality*, *Oxford Bulletin of Economics and Statistics* 2008, vol. 70(s1), s. 927–939.

²⁶ Maddala G.S., dz. cyt.

Rozkład reszt modelu wraz z dopasowaną krzywą normalną przedstawia rysunek 5.



Rysunek 5. Rozkład reszt modelu głównego wraz z krzywą rozkładu normalnego.

Źródło: opracowanie własne na podstawie zbiorów danych z platformy Kaggle (dane pierwotne: SofaScore i FBref).

Test RESET Ramsey'a na poprawność specyfikacji

Poprawność formy funkcyjnej modelu zweryfikowano testem RESET Ramsey'a²⁷ z kwadratem i sześcianiem wartości dopasowanych jako zmiennymi pomocniczymi. Statystyka $F(2, 1990) = 23,47$ z wartością p równą $8,4 \cdot 10^{-11}$ prowadzi do odrzucenia hipotezy zerowej o poprawnej specyfikacji modelu. Wynik sugeruje, że forma funkcyjna modelu może nie w pełni opisywać zależności między zmiennymi – co jest typowe dla modeli tego rodzaju, w których rynek transferowy jest determinowany przez szereg czynników trudno mierzalnych, takich jak potencjał marketingowy zawodnika, historia kontuzji czy sytuacja kontraktowa. Mimo odrzucenia hipotezy zerowej testu RESET model zachowuje wysoką moc objaśniającą ($R^2 = 0,7145$) oraz ekonomicznie sensowne i statystycznie istotne oszacowania wszystkich parametrów. Wynik testu należy interpretować jako sygnał ostrożności przy ekstrapolacji wyników poza zakres danych, a nie jako dyskwalifikację modelu. Rozszerzenie specyfikacji o

²⁷ Ramsey J.B., *Tests for Specification Errors in Classical Linear Least-Squares Regression Analysis*, *Journal of the Royal Statistical Society. Series B (Methodological)* 1969, vol. 31(2), s. 350–371.

dodatkowe zmienne – takie jak pozostały czas kontraktu czy historia kontuzji – mogłoby potencjalnie poprawić dopasowanie, jednak dane te były niedostępne w zastosowanych źródłach, co stanowi ograniczenie niniejszego badania.

Podsumowanie diagnostyki

Przeprowadzone testy diagnostyczne wskazują na dwa istotne ograniczenia modelu: heteroskedastyczność składnika losowego oraz nieliniowość formy funkcyjnej sygnalizowaną przez test RESET. Pierwsze ograniczenie zostało skorygowane przez zastosowanie odpornych błędów standardowych HC1, co zapewnia ważność wnioskowania statystycznego. Drugie stanowi naturalne ograniczenie każdego modelu usiłującego uchwycić złożony mechanizm rynku transferowego w postaci liniowej. Dodatkowo zweryfikowano współliniowość zmiennych objaśniających za pomocą czynnika inflacji wariancji (VIF); poza naturalną i nieszkodliwą dla wnioskowania korelacją członu kwadratowego wieku ze zmienną liniową nie stwierdzono problemu współliniowości. Model zachowuje solidną moc objaśniającą i może służyć jako narzędzie do identyfikacji kluczowych determinant wartości rynkowej piłkarzy, przy zachowaniu świadomości jego ograniczeń. Pełne wydruki testów diagnostycznych zamieszczono w załączniku 2.

W odpowiedzi na niespełnienie założeń stochastycznych przez model główny oszacowano dodatkowo pomocniczy model referencyjny, którego celem jest wykazanie, że na analizowanych danych możliwe jest zbudowanie specyfikacji spełniającej klasyczne założenia KMNK. Model ten objaśnia logarytm wartości rynkowej wyłącznie indywidualnymi statystykami boiskowymi: liczbą goli, asyst, odbiorów i przechwytów oraz oceną meczową. Dla tej specyfikacji test White'a nie daje podstaw do odrzucenia hipotezy o homoskedastyczności składnika losowego ($TR^2 = 16,27$; $\chi^2(10)$; $p = 0,092$), a test RESET nie wskazuje na błędną formę funkcyjną ($F(2, 1998) = 2,84$; $p = 0,059$). Również w tym modelu rozkład reszt nie jest normalny. Nie stanowi to jednak problemu, ponieważ przy tak dużej próbie (2006 obserwacji) oszacowania parametrów mają w przybliżeniu rozkład normalny niezależnie od rozkładu reszt. Gwarantuje to centralne twierdzenie graniczne, dzięki czemu testy istotności pozostają wiarygodne. Ceną za spełnienie założeń jest jednak drastyczny spadek współczynnika determinacji. Wynosi on zaledwie 0,171 wobec 0,715 w modelu głównym. Porównanie to pokazuje, że heteroskedastyczność oraz sygnalizowana przez test RESET nieliniowość nie wynikają z błędu w konstrukcji modelu, lecz są ceną za uwzględnienie zmiennych o największej sile objaśniającej, takich jak prestiż ligi i klubu, czas gry oraz wiek. Z tego względu jako specyfikację główną utrzymano model pełny z odpornymi błędami

standardowymi HC1, które zapewniają poprawność wnioskowania mimo heteroskedastyczności. Pełny wydruk modelu referencyjnego zamieszczono w załączniku 6.

3.3. Empiryczny obraz kluczowych wyznaczników

Oszacowane parametry modelu opisują krańcowy wpływ poszczególnych cech przy założeniu niezmienności pozostałych zmiennych (*ceteris paribus*). Uzupełnieniem tej interpretacji jest analiza surowych, bezwarunkowych rozkładów wartości rynkowej w przekroju kluczowych determinant, pozwalająca ocenić, czy zależności wykryte przez model znajdują odzwierciedlenie w obserwowanych danych. Zestawienia w tabelach 5, 7 i 8 oparto na próbie ograniczonej do zawodników wycenianych na co najmniej 1 mln euro i w wieku do 36 lat, co redukuje wpływ obserwacji skrajnych i błędów źródłowych. Tabela 6 prezentuje natomiast pełną próbę.

Tabela 5 przedstawia profil wartości rynkowej w przedziałach wiekowych. Zarówno średnia, jak i mediana wartości rynkowej są najwyższe w najmłodszej grupie, a od przedziału 24-26 lat wyraźnie i systematycznie maleją. Mediana spada z 15,9 mln euro w grupie 18-20 lat do zaledwie 2,9 mln euro w grupie 33-36 lat. Empiryczny obraz potwierdza zatem malejący wpływ wieku wykryty przez model w obserwowanym zakresie danych.

Tabela 5. Wartość rynkowa według przedziałów wiekowych

Przedział wiekowy	Liczba zawodników	Średnia (mln €)	Mediana (mln €)
18–20	111	22,4	15,9
21–23	402	18,4	11,3
24–26	506	19,2	11,3
27–29	419	15,6	9,1
30–32	201	7,4	4,2
33–36	86	4,0	2,9

Źródło: opracowanie własne na podstawie zbiorów danych z platformy Kaggle (dane pierwotne: SofaScore i FBref). Próba ograniczona: wartość ≥ 1 mln euro, wiek ≤ 36 lat.

Analogicznej obserwacji dostarcza zestawienie wartości rynkowej według ligi (tabela 6).

Tabela 6. Wartość rynkowa według ligi (cała próba)

Liga	Liczba zawodników	Średnia (mln €)	Mediana (mln €)
Premier League	326	31,3	26,0
La Liga	299	15,4	5,8
Bundesliga	272	13,9	7,5
Serie A	312	12,8	8,0
Ligue 1	248	12,3	6,4
Liga Portugal	276	5,3	1,4
Eredivisie	273	3,9	1,4

Źródło: opracowanie własne na podstawie zbiorów danych z platformy Kaggle (dane pierwotne: SofaScore i FBref).

Premier League wyraźnie dominuje – średnia wartość zawodnika (31,3 mln euro) oraz mediana (26,0 mln euro) są wielokrotnie wyższe niż w pozostałych rozgrywkach. Na drugim biegunie znajdują się Liga Portugal oraz Eredivisie, gdzie mediana wartości wynosi zaledwie 1,4 mln euro. Hierarchia ta odpowiada ujemnym i rosnącym co do wartości bezwzględnej współczynnikom przy zmiennych ligowych w modelu.

Wyraźna przewaga Premier League nad pozostałymi ligami – widoczna zarówno w surowych zestawieniach (tabela 6), jak i w oszacowaniach modelu – ma podłoże przede wszystkim finansowe, a nie wprost sportowe. Różnica w poziomie piłkarskim między czołowymi ligami europejskimi jest bowiem stosunkowo niewielka; kluby hiszpańskie czy włoskie regularnie rywalizują o najwyższe trofea kontynentalne, a ostatnie dwa puchary Europy wygrał francuski klub – PSG. Ogromna jest natomiast różnica w sile nabywczej klubów. W sezonie 2023/24 przychody klubów Premier League z praw telewizyjnych (ok. 3,3 mld funtów, tj. ok. 3,9 mld euro) ponad dwukrotnie przewyższały analogiczne wpływy klubów La Liga (1,8 mld euro), a łączne przychody angielskiej ligi (ok. 6,3 mld funtów, tj. ok. 7,4 mld euro) pozostawały najwyższe w Europie.²⁸ Ponieważ wartość rynkowa zawodnika stanowi w istocie szacunek przyszłej kwoty transferu, większa zasobność klubów wprost przekłada się na wyższe wyceny. Co istotne, przewaga ta nie ogranicza się do ścisłej czołówki: środki w Premier League rozłożone są stosunkowo równomiernie pomiędzy kluby, podczas gdy w La Liga koncentrują się w nielicznych zespołach – w zestawieniu Deloitte Money League za sezon 2023/24 aż

²⁸Deloitte, *Annual Review of Football Finance* 2025, <https://www.deloitte.com/uk/en/services/consulting/research/annual-review-of-football-finance-europe-premier-league.html> [dostęp: 07.07.2026].

siedem klubów Premier League znalazło się w pierwszej szesnastce, wobec trzech klubów hiszpańskich.²⁹ Tłumaczy to, dlaczego rozbieżność uwidacznia się najsilniej w wartościach średnich i medianowych: przeciętny klub angielski jest znacznie zamożniejszy niż hiszpański. Należy wreszcie podkreślić, że ujemny współczynnik przy zmiennej ligowej izoluje właśnie ten efekt finansowo-prestiżowy – mierzy różnicę w wycenie przy zachowaniu stałej jakości zawodnika (ocena meczowa), pozycji, wieku oraz statusu klubu – a zatem nie jest artefaktem niższego poziomu sportowego, lecz odzwierciedleniem realnej różnicy w potencjale ekonomicznym rozgrywek.

Premia wizerunkowa związana z przynależnością do czołowego klubu jest równie wyraźna. Średnia wartość rynkowa 392 zawodników reprezentujących kluby zaliczone do elity (top_club = 1) wyniosła 36,6 mln euro, podczas gdy dla pozostałych zawodników było to 8,6 mln euro – ponad czterokrotnie mniej. Choć część tej różnicy wynika z wyższej jakości piłkarzy gromadzonych przez najbogatsze kluby, model - kontrolując jakość za pomocą oceny meczowej i pozostałych zmiennych - wykazuje, że sama przynależność do takiego klubu wiąże się z istotną, niezależną premią.

3.4. Analiza reszt i zawodnicy odstający od wyceny

Reszty modelu, definiowane jako różnica między rzeczywistą a teoretyczną (wynikającą z modelu) wartością logarytmu wyceny, niosą cenną informację interpretacyjną. Dodatnia reszta oznacza, że zawodnik jest wyceniany przez rynek wyżej, niż wynikałoby to z jego charakterystyk uwzględnionych w modelu (przeszacowanie), natomiast reszta ujemna wskazuje na wycenę niższą od modelowej (niedoszacowanie). Analiza obserwacji o największych co do wartości bezwzględnej resztach pozwala zidentyfikować zawodników odstających oraz - co istotniejsze - zrozumieć systematyczne mechanizmy, których model nie uchwycił. Zestawienia w tabelach 7 i 8 oparto na próbie ograniczonej analogicznie jak w podrozdziale 3.3 (wartość rynkowa co najmniej 1 mln euro oraz wiek do 36 lat), co eliminuje obserwacje obciążone błędami danych źródłowych.

Tabela 7 przedstawia zawodników najsilniej niedoszacowanych przez rynek względem wyceny modelowej. Dominują wśród nich zawodnicy z lig o niższym prestiżu niż Premier League (przede wszystkim Ligue 1 i Serie A), których rzeczywista wartość rynkowa jest znacząco niższa od wyceny modelowej. Przykładowo Bryan Okoh, 22-letni obrońca z Ligue 1,

²⁹ Deloitte, *Football Money League 2025*, <https://www.deloitte.com/global/en/industries/tmt/analysis/deloitte-football-money-league.html> [dostęp: 07.07.2026].

wyceniany jest na 1,2 mln euro, podczas gdy model, na podstawie jego oceny meczowej, czasu gry i wieku, przewiduje wartość 10,6 mln euro.

Tabela 7. Zawodnicy najsilniej niedoszacowani przez rynek względem wyceny modelowej (reszta ujemna)

Zawodnik	Liga	Poz.	Wiek	Wartość rzeczywista (mln €)	Wartość modelowa (mln €)	Reszta
Bryan Okoh	Ligue 1	D	22	1,2	10,6	-2,18
Aladji Bamba	Ligue 1	M	19	3,2	20,2	-1,84
Jochem Ritmeester van de Kamp	Eredivisie	F	22	1,4	7,6	-1,69
Noah Cadiou	Ligue 1	M	27	1,0	5,3	-1,67
Federico Bonazzoli	Serie A	F	28	2,3	11,0	-1,57
Danilo Veiga	Serie A	D	23	1,9	8,8	-1,53
Lautaro Valenti	Serie A	D	27	1,6	7,3	-1,52

Źródło: opracowanie własne na podstawie zbiorów danych z platformy Kaggle (dane pierwotne: SofaScore i FBref). Reszta wyrażona w jednostkach logarytmu naturalnego wartości rynkowej i obliczona na wartościach dokładnych; wyceny w tabeli zaokrąglono do 0,1 mln euro. Próba ograniczona: wartość ≥ 1 mln euro, wiek ≤ 36 lat.

Wartości skrajnie niedoszacowane wskazują przede wszystkim na ograniczenia oceny meczowej jako miary jakości w przypadku zawodników defensywnych występujących w słabszych zespołach – wysoka nota meczowa w połączeniu z regularną grą winduje wycenę modelową, podczas gdy rynek pozostaje wobec takich graczy bardziej sceptyczny.

Odwrotne zjawisko – silne przeszacowanie – przedstawia tabela 8. Tutaj obraz jest wyjątkowo spójny: wśród najbardziej przewartościowanych zawodników dominują młodzi napastnicy i ofensywni pomocnicy z Ligi Portugal oraz Eredivisie. Zawodnicy tacy jak Samu Aghehowa (52 mln euro przy wycenie modelowej 4,3 mln euro), Geovany Quenda czy Rodrigo Mora są wyceniani przez rynek wielokrotnie wyżej, niż wynikałoby to z ich bieżących statystyk.

Tabela 8. Zawodnicy najsilniej przeszacowani przez rynek względem wyceny modelowej (reszta dodatnia)

Zawodnik	Liga	Poz.	Wiek	Wartość rzeczywista (mln €)	Wartość modelowa (mln €)	Reszta
Geovany Quenda	Liga Portugal	M	19	49,0	2,7	+2,89
Rodrigo Mora	Liga Portugal	M	18	42,0	2,9	+2,69
Givairo Read	Eredivisie	D	19	24,0	1,8	+2,59
Ousmane Diomande	Liga Portugal	D	22	48,0	3,9	+2,51
Samu Aghehowa	Liga Portugal	F	22	52,0	4,3	+2,48

Maximiliano Araújo	Liga Portugal	M	26	23,0	2,0	+2,46
Kasper Dolberg	Eredivisie	F	28	10,9	0,9	+2,44

Źródło: opracowanie własne na podstawie zbiorów danych z platformy Kaggle (dane pierwotne: SofaScore i FBref). Reszta wyrażona w jednostkach logarytmu naturalnego wartości rynkowej i obliczona na wartościach dokładnych; wyceny w tabeli zaokrąglono do 0,1 mln euro. Próba ograniczona: wartość ≥ 1 mln euro, wiek ≤ 36 lat.

Spójność tego wzorca wskazuje na istnienie systematycznego mechanizmu, który można określić mianem „efektu witryny wystawowej”. Szczególnie wymownym przykładem działania tego efektu jest przypadek Samu Aghehowy – 22-letniego napastnika FC Porto, którego rynkowa wycena (52 mln euro) ponad dwunastokrotnie przewyższa wartość przewidywaną przez model (4,3 mln euro). Rozbieżność ta nie wynika z błędu specyfikacji, lecz z samej konstrukcji modelu, który szacuje warunkową wartość oczekiwaną zawodnika o danym zestawie cech. Po pierwsze, jakość piłkarza reprezentowana jest wyłącznie przez ocenę meczową – zmienną o niewielkim rozrzucie (odchylenie standardowe 0,22) – przez co nawet wysoka skuteczność strzelecka nie przekłada się na proporcjonalny wzrost wartości modelowej; liczba bramek, zgodnie z przyjętą specyfikacją weryfikującą hipotezę trzecią, nie wchodzi bezpośrednio do modelu. Po drugie, zawodnik obciążony jest silną karą ligową (Liga Portugal, dyskonto rzędu 88% względem Premier League) i nie korzysta z premii wizerunkowej, ponieważ FC Porto nie zostało zaliczone do grona klubów elitarnych. Rynek wycenia natomiast nie tyle bieżące osiągnięcia zawodnika, ile oczekiwany, bliski transfer do silniejszej ligi – wartość, której model oparty na charakterystykach z bieżącego sezonu nie jest w stanie uchwycić. Przypadek ten dobrze ilustruje, że największe dodatnie reszty modelu mają charakter systematyczny i interpretowalny, a nie losowy. Kluby takie jak Benfica, FC Porto czy Sporting CP pełnią na europejskim rynku transferowym rolę pośredników w handlu talentami - pozyskują młodych, utalentowanych zawodników, eksponują ich w rozgrywkach krajowych i europejskich pucharach, a następnie odsprzedają z wysoką marżą do najbogatszych lig. Wycena rynkowa takich zawodników odzwierciedla nie tyle ich bieżące statystyki, ile oczekiwania co do przyszłego transferu do silniejszej ligi oraz potencjał wzrostu wartości. Model oparty na bieżących wskaźnikach sportowych systematycznie zaniża wartość tych zawodników, co stanowi naturalne i interpretowalne ograniczenie przyjętej specyfikacji.

3.5. Weryfikacja hipotez badawczych

Przeprowadzona analiza empiryczna pozwala ustosunkować się do trzech hipotez badawczych sformułowanych w rozdziale 2.

Hipoteza 1, zakładająca nieliniowy wpływ wieku na wartość rynkową, znajduje potwierdzenie. Oba parametry opisujące wiek – człon liniowy (0,1919) oraz kwadratowy (-0,005901) – są istotne statystycznie na poziomie 1%, a ich znaki wskazują na zależność paraboliczną. W całym obserwowanym zakresie wieku (18–42 lata) wartość rynkowa maleje wraz z wiekiem, a tempo tego spadku rośnie; potwierdza to również empiryczny profil wieku przedstawiony w tabeli 5.

Hipoteza 2, dotycząca wpływu prestiżu ligi oraz przynależności do czołowego klubu, również została potwierdzona. Wszystkie sześć zmiennych ligowych jest istotnych statystycznie i ujemnych względem Premier League, co dowodzi istnienia wyraźnej hierarchii ligowej. Zmienna *top_club* wykazała silną, niezależną premię wizerunkową rzędu 155%. Oba efekty utrzymują się po uwzględnieniu jakości zawodnika mierzonej oceną meczową, co potwierdza, że prestiż klubu i ligi stanowi samodzielną determinantę wyceny.

Hipoteza 3, zakładająca wystarczalność oceny meczowej jako syntetycznego wyznacznika jakości, znajduje pełne potwierdzenie. W celu jej weryfikacji oszacowano dwa modele porównawcze wobec modelu bazowego opartego na ocenie meczowej. W pierwszym z nich do oceny meczowej dołączono pełny zestaw tradycyjnych statystyk sportowych (*m.in.* gole, asysty, oczekiwane gole i asysty, strzały i strzały celne, liczbę występów, kartki, odbiory oraz przechwyty); w drugim natomiast ocenę meczową usunięto, pozostawiając wyłącznie te statystyki. We wszystkich modelach zachowano pozostałe zmienne kontrolne. Zestawienie miar dopasowania trzech modeli przedstawia tabela 9.

Wynik okazał się nawet silniejszy, niż zakładała hipoteza. Model oparty na pojedynczej ocenie meczowej nie tylko nie traci na mocy objaśniającej, lecz wręcz nieznacznie przewyższa model oparty na surowych statystykach – osiąga wyższe R^2 (0,7145 wobec 0,6965) oraz skorygowane R^2 , niższy błąd standardowy reszt, a także niższe niż w modelu B wartości kryteriów informacyjnych Akaikego i Schwarza przy znacznie mniejszej liczbie szacowanych parametrów. Model A uzyskuje wprawdzie najniższe wartości AIC i BIC spośród trzech specyfikacji, jednak minimalny przyrost dopasowania nie rekompensuje wprowadzanej przez niego współliniowości oraz utraty interpretowalności części parametrów. Dołączenie pełnego zestawu statystyk do modelu opartego na ocenie meczowej podnosi współczynnik determinacji jedynie nieznacznie – z 0,7145 do 0,7289 – co oznacza, że ocena meczowa zawiera niemal całą informację zawartą w tych statystykach. Model łączący oba źródła wprowadza przy tym współliniowość, w wyniku której część współczynników przy statystykach traci istotność lub przyjmuje ekonomicznie nieuzasadnione znaki, dlatego jako specyfikację główną wybrano oszczędniejszy model oparty na samej ocenie meczowej. Pełny wydruk modelu rozszerzonego

zamieszczono w załączniku 3, a modelu opartego wyłącznie na tradycyjnych statystykach w załączniku 4. Wyniki te pokazują, że jedna syntetyczna zmienna skuteczniej streszcza jakość zawodnika niż rozbudowany zbiór pojedynczych wskaźników, a dodatkowo – będąc liczona odmiennie dla poszczególnych pozycji – nie dyskryminuje zawodników formacji defensywnych, których wartości nie sposób trafnie ująć statystykami ofensywnymi. Hipoteza 3 zostaje tym samym potwierdzona.

Tabela 9. Miary dopasowania modelu bazowego oraz dwóch modeli porównawczych

Miara dopasowania	Model bazowy (rating)	Model A (rating + wszystkie statystyki)	Model B (wszystkie statystyki bez oceny meczowej)
Współczynnik determinacji R^2	0,7145	0,7289	0,6965
Skorygowane R^2	0,7127	0,7255	0,6928
Błąd standardowy reszt	0,7743	0,7568	0,8005
Kryterium informacyjne Akaikego (AIC)	4680,4	4600,5	4825,0
Kryterium bayesowskie Schwarza (BIC)	4758,8	4746,2	4965,1
Liczba szacowanych parametrów	14	26	25

Źródło: opracowanie własne na podstawie zbiorów danych z platformy Kaggle (dane pierwotne: SofaScore i FBref). Niższe wartości kryteriów AIC i BIC oznaczają lepsze dopasowanie modelu.

Dodatkowo wprowadzenie zmiennych pozycji potwierdziło ekonomiczną spójność modelu – napastnicy uzyskują istotną premię (około 42%) względem obrońców, podczas gdy różnica między pomocnikami a obrońcami pozostaje nieistotna. Analiza reszt ujawniła natomiast systematyczne ograniczenie modelu: w przypadku młodych zawodników z lig pełniących rolę „witryn wystawowych” bieżąca ocena meczowa nie oddaje w pełni rynkowej wyceny ich potencjału. Ograniczenie to nie podważa ogólnej trafności modelu, lecz wyznacza kierunek jego potencjalnego rozwoju, omówiony w zakończeniu pracy.

Zakończenie

Celem niniejszej pracy była identyfikacja i ocena siły wpływu czynników determinujących wartość rynkową profesjonalnych piłkarzy występujących w czołowych ligach europejskich. Cel ten zrealizowano poprzez budowę modelu ekonometrycznego opartego na koncepcji cen hedonicznych oraz teorii kapitału ludzkiego, estymowanego klasyczną metodą najmniejszych kwadratów na próbie ponad dwóch tysięcy zawodników z siedmiu najsilniejszych lig europejskich. Przeprowadzone badanie pozwoliło na sformułowanie kilku istotnych wniosków.

Po pierwsze, oszacowany model wykazał wysoką moc objaśniającą – uwzględnione zmienne wyjaśniły ponad 71% zmienności logarytmu wartości rynkowej piłkarzy, a niemal wszystkie zmienne objaśniające okazały się istotne statystycznie. Potwierdza to, że wartość rynkowa zawodnika, mimo iż kształtowana przez wiele trudno mierzalnych czynników, w znacznym stopniu poddaje się modelowaniu ilościowemu na podstawie podstawowych charakterystyk sportowych i demograficznych.

Po drugie, przeprowadzona analiza pozwoliła na potwierdzenie wszystkich trzech postawionych hipotez badawczych. Wykazano, że wiek zawodnika wpływa na jego wartość w sposób nieliniowy, zgodny z teoretycznym profilem cyklu kariery sportowca. W ujęciu surowym wartość utrzymuje się na najwyższym poziomie w młodszych przedziałach wiekowych i wyraźnie maleje po przekroczeniu około 26. roku życia, natomiast po uwzględnieniu pozostałych zmiennych modelu maleje w całym obserwowanym zakresie wieku, a tempo tego spadku rośnie. Potwierdzono również istnienie wyraźnej hierarchii ligowej oraz samodzielnej premii wizerunkowej związanej z przynależnością do klubu ze światowej czołówki, niezależnej od indywidualnych statystyk zawodnika. Wreszcie wykazano, że syntetyczna ocena meczowa stanowi skuteczny i wystarczający wyznacznik jakości piłkarza – model oparty wyłącznie na ocenie meczowej przewyższał modele zbudowane na samych tradycyjnych statystykach, a jednocześnie uwzględnienie oceny meczowej i pełnego zestawu statystyk poprawiało dopasowanie jedynie nieznacznie, wprowadzając przy tym nadmierną współliniowość.

Po trzecie, analiza reszt modelu dostarczyła wniosków wykraczających poza sam pomiar siły zależności. Pozwoliła zidentyfikować zawodników, których wartość rynkowa istotnie odbiega od wyceny modelowej, oraz wskazać ekonomiczne przyczyny tych odchyleń. Szczególnie interesującym zjawiskiem okazała się systematyczna przewaga rynkowej wyceny młodych, utalentowanych zawodników z lig o niższym prestiżu nad wyceną modelową –

zjawisko określone w pracy jako efekt witryny wystawowej, w którym rynek wycenia zawodnika nie według jego bieżącego środowiska sportowego, lecz w oczekiwaniu na przyszły transfer do silniejszej ligi.

Przeprowadzone badanie nie jest wolne od ograniczeń, które należy uwzględnić przy interpretacji wyników. Przede wszystkim testy diagnostyczne wskazały na występowanie heteroskedastyczności składnika losowego oraz na niedoskonałość formy funkcyjnej sygnalizowaną przez test specyfikacji. Pierwsze ograniczenie skorygowano poprzez zastosowanie odpornych błędów standardowych, drugie zaś stanowi naturalną konsekwencję próby ujęcia złożonego mechanizmu rynkowego w postaci modelu liniowego. Istotnym ograniczeniem jest również niedostępność niektórych potencjalnie ważnych zmiennych – takich jak pozostały czas trwania kontraktu, historia kontuzji czy popularność zawodnika w mediach społecznościowych – które mogłyby dodatkowo poprawić dopasowanie modelu. Ponadto matematyczny szczyt funkcji wieku okazał się zniekształcony przez obecność w próbie wyjątkowo utalentowanych juniorów, co ogranicza możliwość jego bezpośredniej interpretacji.

Wskazane ograniczenia wyznaczają zarazem kierunki możliwych dalszych badań. Naturalnym rozszerzeniem byłoby uwzględnienie zmiennych kontraktowych i marketingowych, których włączenie mogłoby pozwolić na uchwycenie czynników odpowiedzialnych za największe odchylenia od wyceny modelowej. Interesującym kierunkiem byłoby także zastosowanie bardziej elastycznych metod modelowania, zdolnych lepiej odwzorować nieliniowe zależności rynkowe, oraz rozszerzenie analizy o wymiar dynamiczny, pozwalający śledzić zmiany wartości zawodników w czasie.

Podsumowując, przeprowadzone badanie potwierdziło, że wartość rynkowa piłkarzy poddaje się systematycznej analizie ekonometrycznej, a kluczowymi jej determinantami są jakość sportowa wyrażona oceną meczową, wiek zawodnika oraz prestiż jego środowiska sportowego. Jednocześnie badanie ujawniło granice formalnego modelowania, wskazując na istnienie zjawisk – związanych przede wszystkim z oczekiwaniami rynku co do przyszłości zawodnika – które wymykają się ujęciu ilościowemu i stanowią obszar wart dalszej eksploracji.

Bibliografia

Książki i artykuły naukowe

Becker G.S., Human Capital: A Theoretical and Empirical Analysis, with Special Reference to Education, Columbia University Press, New York 1964.

Carmichael F., Forrest D., Simmons R., The Labour Market in Association Football: Who Gets Transferred and For How Much?, *Bulletin of Economic Research* 1999, vol. 51(2), s. 125–150.

Dobson S., Gerrard B., The Determination of Player Transfer Fees in English Professional Soccer, *Journal of Sport Management* 1999, vol. 13(4), s. 259–279.

Doornik J.A., Hansen H., An Omnibus Test for Univariate and Multivariate Normality, *Oxford Bulletin of Economics and Statistics* 2008, vol. 70(s1), s. 927–939.

FIFA, Regulations on the Status and Transfer of Players, FIFA, Zurich 2024.

Franck E., Nüesch S., Talent and/or Popularity: What Does It Take to Be a Superstar?, *Economic Inquiry* 2012, vol. 50(1), s. 202–216.

Frick B., The Football Players' Labor Market: Empirical Evidence from the Major European Leagues, *Scottish Journal of Political Economy* 2007, vol. 54(3), s. 422–446.

Herm S., Callsen-Bracker H.-M., Kreis H., When the Crowd Evaluates Soccer Players' Market Values: Accuracy and Evaluation Attributes of an Online Community, *Sport Management Review* 2014, vol. 17(4), s. 484–492.

MacKinnon J.G., White H., Some Heteroskedasticity-Consistent Covariance Matrix Estimators with Improved Finite Sample Properties, *Journal of Econometrics* 1985, vol. 29(3), s. 305–325.

Maddala G.S., Ekonometria, Wydawnictwo Naukowe PWN, Warszawa 2006.

Müller O., Simons A., Weinmann M., Beyond Crowd Judgments: Data-Driven Estimation of Market Value in Association Football, *European Journal of Operational Research* 2017, vol. 263(2), s. 611–624.

Ramsey J.B., Tests for Specification Errors in Classical Linear Least-Squares Regression Analysis, *Journal of the Royal Statistical Society. Series B (Methodological)* 1969, vol. 31(2), s. 350–371.

Rosen S., Hedonic Prices and Implicit Markets: Product Differentiation in Pure Competition, *Journal of Political Economy* 1974, vol. 82(1), s. 34–55.

Sznajder A., *Marketing sportu*, PWE, Warszawa 2015.

White H., A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity, *Econometrica* 1980, vol. 48(4), s. 817–838.

Źródła internetowe

BBC Sport. *Neymar to blame for inflated transfer fees – Barcelona vice-president*. [online] <https://www.bbc.com/sport/football/42938945> [dostęp: 07.07.2026].

Deloitte, Annual Review of Football Finance 2025, <https://www.deloitte.com/uk/en/services/consulting/research/annual-review-of-football-finance-europe-premier-league.html> [dostęp: 07.07.2026].

Deloitte, Football Money League 2025, <https://www.deloitte.com/global/en/industries/tmt/analysis/deloitte-football-money-league.html> [dostęp: 07.07.2026].

Klemba A., *Na transferze Lewandowskiego do Barcelony zarobią Legia i Lech, ale najwięcej Varsovia!*, Interia Sport, <https://sport.interia.pl/robert-lewandowski/news-na-transferze-lewandowskiego-do-barcelony-zarobia-legia-i-le,nId,6160483> [dostęp: 07.07.2026].

Sidorowicz H., Football Players Stats (2025–2026) [zbiór danych], Kaggle, <https://www.kaggle.com/datasets/hubertsidorowicz/football-players-stats-2025-2026> [dostęp: 07.07.2026].

UEFA, Country coefficients, <https://www.uefa.com/nationalassociations/uefarankings/country/> [dostęp: 07.07.2026].

Yorgun K., European Top Leagues Player Stats 25-26 [zbiór danych], Kaggle, <https://www.kaggle.com/datasets/kaanyorgun/european-top-leagues-player-stats-25-26> [dostęp: 07.07.2026].

Spis tabel

Tabela 1. Przegląd badań empirycznych nad determinantami wartości rynkowej piłkarzy	9
Tabela 2. Statystyki opisowe zmiennych ilościowych (N = 2006)	17
Tabela 3. Wyniki estymacji modelu log-liniowego (błędy standardowe HC1).....	20
Tabela 4. Wyniki testów diagnostycznych modelu	24
Tabela 5. Wartość rynkowa według przedziałów wiekowych.....	28
Tabela 6. Wartość rynkowa według ligi (cała próba)	29
Tabela 7. Zawodnicy najsilniej niedoszacowani przez rynek względem wyceny modelowej (reszta ujemna)	31
Tabela 8. Zawodnicy najsilniej przeszacowani przez rynek względem wyceny modelowej (reszta dodatnia)	31
Tabela 9. Miary dopasowania modelu bazowego oraz dwóch modeli porównawczych.....	34

Spis rysunków

Rysunek 1. Rozkład wartości rynkowej zawodników w próbie badawczej (przed transformacją logarytmiczną).....	14
Rysunek 2. Rozkład logarytmu naturalnego wartości rynkowej zawodników.....	15
Rysunek 3. Zależność logarytmu wartości rynkowej od wieku zawodnika wraz z dopasowaną funkcją kwadratową.	23
Rysunek 4. Rozkład wartości rynkowej zawodników według ligi (wykresy pudełkowe).....	24
Rysunek 5. Rozkład reszt modelu głównego wraz z krzywą rozkładu normalnego.	26

Załączniki

Załącznik 1: Estymacja modelu głównego

gretl: model 2				
Plik Edycja Testy Zapisz Wykresy Analiza LaTeX				
Model 2: Estymacja KMNK, wykorzystane obserwacje 1-2006				
Zmienna zależna (Y): l_market_value				
Błędy standardowe parametrów według odpornej heteroskedastyczności, wariant HCl				
	współczynnik	błąd standardowy	t-Studenta	wartość p
-----	-----	-----	-----	-----
const	-0,763847	0,911856	-0,8377	0,4023
rating	1,96577	0,0914865	21,49	2,79e-092 ***
age_new	0,191885	0,0537805	3,568	0,0004 ***
sq_age_new	-0,00590146	0,000985705	-5,987	2,53e-09 ***
top_club	0,935392	0,0391506	23,89	3,84e-111 ***
Dleague_1	-2,29850	0,0672052	-34,20	4,32e-202 ***
Dleague_2	-0,995081	0,0481036	-20,69	2,85e-086 ***
Dleague_3	-0,898751	0,0460646	-19,51	1,01e-077 ***
Dleague_4	-0,865819	0,0467222	-18,53	7,42e-071 ***
Dleague_5	-1,05630	0,0539566	-19,58	3,41e-078 ***
Dleague_6	-2,15978	0,0745336	-28,98	2,35e-154 ***
Dpos_fbref_1	0,0329485	0,0403966	0,8156	0,4148
Dpos_fbref_2	0,351150	0,0461156	7,615	4,06e-014 ***
l_minutes_played	0,404818	0,0489805	8,265	2,52e-016 ***
Średn.aryt.zm.zależnej	15,59413	Odch.stand.zm.zależnej	1,444419	
Suma kwadratów reszt	1194,224	Błąd standardowy reszt	0,774280	
Wsp. determ. R-kwadrat	0,714514	Skorygowany R-kwadrat	0,712651	
F(13, 1992)	473,6725	Wartość p dla testu F	0,000000	
Logarytm wiarygodności	-2326,189	Kryt. inform. Akaike'a	4680,378	
Kryt. bayes. Schwarza	4758,833	Kryt. Hannana-Quinna	4709,181	
Wyłączając stałą, największa wartość p jest dla zmiennej 35 (Dpos_fbref_1)				

Załącznik 2: Diagnostyka modelu głównego

gretl: test RESET (Regression Equation Specification Error Test)

Pomocnicze równanie regresji dla testu specyfikacji RESET
 Estymacja KMNK, wykorzystane obserwacje 1-2006
 Zmienna zależna (Y): l_market_value

	współczynnik	błąd standardowy	t-Studenta	wartość p
const	93,3382	15,8215	5,899	4,28e-09 ***
rating	-30,4434	5,31778	-5,725	1,19e-08 ***
age_new	-2,95285	0,510955	-5,779	8,70e-09 ***
sq_age_new	0,0911449	0,0158014	5,768	9,27e-09 ***
top_club	-14,4743	2,53724	-5,705	1,34e-08 ***
Dleague_1	35,7401	6,23611	5,731	1,15e-08 ***
Dleague_2	15,4190	2,70076	5,709	1,31e-08 ***
Dleague_3	13,9112	2,43722	5,708	1,32e-08 ***
Dleague_4	13,3914	2,34751	5,705	1,34e-08 ***
Dleague_5	16,3602	2,86453	5,711	1,29e-08 ***
Dleague_6	33,5890	5,86067	5,731	1,15e-08 ***
Dpos_fbref_1	-0,512247	0,0972332	-5,268	1,53e-07 ***
Dpos_fbref_2	-5,44459	0,952326	-5,717	1,25e-08 ***
l_minutes_played	-6,29933	1,10008	-5,726	1,18e-08 ***
yhat^2	1,09801	0,175129	6,270	4,42e-010 ***
yhat^3	-0,0241318	0,00376087	-6,417	1,74e-010 ***

Hipoteza zerowa: specyfikacja poprawna
 Statystyka testu: F = 23,472656,
 z wartością p = P(F(2,1990) > 23,4727) = 8,4e-011


gretl: test LM - mnożnika Lagrange'a (heteroskedastyczność)

Test White'a na heteroskedastyczność reszt (zmiennosc wariacji resztowej) (tylko kwadrat zmiennej zależnej ^y)
 Estymacja KMNK, wykorzystane obserwacje 1-2006
 Zmienna zależna (Y): uhat^2
 Z powodu ścisłej współliniowości pominięto zmienną: sq_age_new

	współczynnik	błąd standardowy	t-Studenta	wartość p
const	-12,9716	13,7861	-0,9409	0,3469
rating	7,79234	3,52122	2,213	0,0270 **
age_new	-0,0993416	0,236914	-0,4193	0,6750
sq_age_new	0,000673024	0,00637601	0,1056	0,9159
top_club	-0,0879951	0,0600010	-1,467	0,1427
Dleague_1	0,609408	0,0825340	7,384	2,25e-013 ***
Dleague_2	0,149041	0,0776759	1,919	0,0552 *
Dleague_3	0,0810184	0,0797576	1,016	0,3098
Dleague_4	0,164112	0,0765300	2,144	0,0321 **
Dleague_5	0,204472	0,0822797	2,485	0,0130 **
Dleague_6	0,995079	0,0821045	12,12	1,14e-032 ***
Dpos_fbref_1	-0,0233548	0,0500352	-0,4668	0,6407
Dpos_fbref_2	-0,000348926	0,0579258	-0,006024	0,9952
l_minutes_played	-3,35573	1,92033	-1,747	0,0807 *
sq_rating	-0,529184	0,254548	-2,079	0,0378 **
sq_sq_age_new	5,90257e-07	1,30512e-06	0,4523	0,6511
sq_l_minutes_pla~	0,207303	0,133474	1,553	0,1205

Wsp. determ. R-kwadrat = 0,148107

Statystyka testu: TR^2 = 297,101840,
 z wartością p = P(Chi-kwadrat(16) > 297,101840) = 0,000000



gretl: ocena współliniowości VIF (Variance Inflation Factor)

Ocena współliniowości VIF(j) - czynnik rozdęcia wariancji

VIF (Variance Inflation Factors) - minimalna możliwa wartość = 1.0

Wartości > 10.0 mogą wskazywać na problem współliniowości - rozdęcia wariancji

rating	1,297
age_new	103,957
sq_age_new	103,539
top_club	1,216
Dleague_1	1,735
Dleague_2	1,653
Dleague_3	1,605
Dleague_4	1,672
Dleague_5	1,584
Dleague_6	1,723
Dpos_fbref_1	1,302
Dpos_fbref_2	1,305
l_minutes_played	1,243

VIF(j) = 1/(1 - R(j)^2), gdzie R(j) jest współczynnikiem korelacji wielorakiej pomiędzy zmienną 'j' a pozostałymi zmiennymi niezależnymi modelu.

gretl: ocena współliniowości VIF (Variance Inflation Factor)

Diagnostyka współliniowości wg. Belsley-Kuh-Welsch (BKW, 1980):

Proporcje wariancji (variance proportions)

lambda	cond	const	rating	age_new	sq_age_n~	top_club	Dleague_1	Dleague_2
6,799	1,000	0,000	0,000	0,000	0,000	0,004	0,001	0,002
1,114	2,470	0,000	0,000	0,000	0,000	0,083	0,262	0,000
1,044	2,552	0,000	0,000	0,000	0,000	0,009	0,092	0,145
1,003	2,604	0,000	0,000	0,000	0,000	0,000	0,044	0,299
0,994	2,616	0,000	0,000	0,000	0,000	0,001	0,085	0,003
0,972	2,645	0,000	0,000	0,000	0,000	0,000	0,032	0,001
0,851	2,827	0,000	0,000	0,000	0,000	0,015	0,117	0,034
0,645	3,246	0,000	0,000	0,000	0,000	0,671	0,065	0,007
0,306	4,715	0,000	0,000	0,000	0,000	0,001	0,045	0,064
0,225	5,503	0,000	0,000	0,000	0,000	0,058	0,227	0,431
0,047	12,042	0,001	0,001	0,000	0,005	0,030	0,004	0,003
0,001	76,319	0,048	0,043	0,003	0,004	0,020	0,001	0,009
0,000	136,178	0,202	0,929	0,024	0,023	0,106	0,001	0,000
0,000	311,432	0,749	0,027	0,973	0,967	0,001	0,026	0,001

lambda	cond	Dleague_3	Dleague_4	Dleague_5	Dleague_6	Dpos_fbref_1	Dpos_fbref_2	l_minute~
6,799	1,000	0,003	0,003	0,002	0,001	0,004	0,004	0,000
1,114	2,470	0,071	0,017	0,007	0,143	0,010	0,024	0,000
1,044	2,552	0,009	0,144	0,056	0,070	0,030	0,054	0,000
1,003	2,604	0,027	0,000	0,204	0,096	0,000	0,001	0,000
0,994	2,616	0,279	0,247	0,009	0,022	0,000	0,000	0,000
0,972	2,645	0,039	0,007	0,314	0,361	0,002	0,000	0,000
0,851	2,827	0,003	0,036	0,011	0,002	0,114	0,310	0,000
0,645	3,246	0,074	0,064	0,001	0,036	0,012	0,000	0,000
0,306	4,715	0,102	0,109	0,092	0,004	0,667	0,469	0,000
0,225	5,503	0,384	0,372	0,298	0,220	0,103	0,072	0,000
0,047	12,042	0,000	0,000	0,002	0,006	0,014	0,009	0,005
0,001	76,319	0,006	0,000	0,000	0,000	0,022	0,047	0,947
0,000	136,178	0,002	0,000	0,003	0,033	0,016	0,000	0,042
0,000	311,432	0,000	0,001	0,001	0,006	0,005	0,010	0,006

lambda = wartości własne odwrotnej macierzy kowariancji (najmniejszy jest 7,00989e-005)

cond = wskaźnik stanu (condition index)

uwaga: proporcje wariancji w kolumnach mają sumę równą 1.0

Według BKW, cond >= 30 oznacza "silną" prawie liniową współzależność, dla cond pomiędzy 10 a 30 "umiarkowanie silną" współzależność. Oszacowane parametry, których wariancja jest związana z wysokimi wartościami wskaźnika stanu, zawsze mogą być uznane za problematyczne.

Liczba wskaźników stanu dla cond >= 30: 3

Suma proporcji wariancji >= 0.5 dla cond >= 30:

const	rating	age_new	sq_age_n~	l_minute~
0,999	0,999	1,000	0,995	0,995

Liczba wskaźników stanu dla cond >= 10: 4

Suma proporcji wariancji >= 0.5 dla cond >= 10:

const	rating	age_new	sq_age_n~	l_minute~
1,000	1,000	1,000	1,000	1,000

Załącznik 3: Model pomocniczy ze wszystkimi zmiennymi

gretl: model 1					
Plik Edycja Testy Zapisz Wykresy Analiza LaTeX					
Model 1: Estymacja KMNK, wykorzystane obserwacje 1-2006					
Zmienna zależna (Y): l_market_value					
Błędy standardowe parametrów według odpornej heteroskedastyczności, wariant HCl					
	współczynnik	błąd standardowy	t-Studenta	wartość p	
const	-0,0587230	1,70557	-0,03443	0,9725	
appearances	-0,0105194	0,00637613	-1,650	0,0991	*
matches_started	-0,0100003	0,0106003	-0,9434	0,3456	
goals	-0,0253398	0,0155288	-1,632	0,1029	
assists	0,0377245	0,0152501	2,474	0,0135	**
expected_goals	0,0783209	0,0200149	3,913	9,42e-05	***
expected_assists	0,0155746	0,0188264	0,8273	0,4082	
rating	1,73909	0,119217	14,59	7,38e-046	***
total_shots	-0,000869062	0,00329257	-0,2639	0,7918	
shots_on_target	0,00423130	0,00836028	0,5061	0,6128	
yellow_cards	-0,00159193	0,00896639	-0,1775	0,8591	
red_cards	0,0759425	0,0418224	1,816	0,0695	*
tackles	-0,00374663	0,00170821	-2,193	0,0284	**
interceptions	-0,000329887	0,00277827	-0,1187	0,9055	
age_new	0,182698	0,0527055	3,466	0,0005	***
top_club	0,868915	0,0383460	22,66	2,87e-101	***
Dleague_1	-2,39341	0,0673373	-35,54	1,87e-214	***
Dleague_2	-1,00514	0,0483667	-20,78	6,20e-087	***
Dleague_3	-0,951533	0,0465793	-20,43	2,53e-084	***
Dleague_4	-0,839732	0,0455840	-18,42	4,51e-070	***
Dleague_5	-1,10153	0,0545100	-20,21	1,04e-082	***
Dleague_6	-2,20942	0,0742991	-29,74	5,78e-161	***
Dpos_fbref_1	-0,0567268	0,0491558	-1,154	0,2486	
Dpos_fbref_2	0,00811943	0,0706854	0,1149	0,9086	
sq_age_new	-0,00577333	0,000966574	-5,973	2,75e-09	***
l_minutes_played	0,602379	0,215843	2,791	0,0053	***
Średn.aryt.zm.zależnej	15,59413	Odch.stand.zm.zależnej	1,444419		
Suma kwadratów reszt	1133,962	Błąd standardowy reszt	0,756775		
Wsp. determ. R-kwadrat	0,728920	Skorygowany R-kwadrat	0,725497		
F(25, 1980)	246,4979	Wartość p dla testu F	0,000000		
Logarytm wiarygodności	-2274,255	Kryt. inform. Akaike'a	4600,510		
Kryt. bayes. Schwarza	4746,211	Kryt. Hannana-Quinna	4654,000		
Wylączając stałą, największa wartość p jest dla zmiennej 36 (Dpos_fbref_2)					

Załącznik 4: Model pomocniczy ze wszystkimi zmiennymi z wyłączeniem zmiennej „rating”

gretl: model 1				
Plik Edycja Testy Zapisz Wykresy Analiza LaTeX				
Model 1: Estymacja KMNK, wykorzystane obserwacje 1-2006				
Zmienna zależna (Y): l_market_value				
Błędy standardowe parametrów według odpornej heteroskedastyczności, wariant HCl				
	współczynnik	błąd standardowy	t-Studenta	wartość p
const	9,91813	1,59151	6,232	5,62e-010 ***
appearances	-0,0403129	0,00627400	-6,425	1,64e-010 ***
matches_started	-0,0172262	0,0111765	-1,541	0,1234
goals	0,0563949	0,0146420	3,852	0,0001 ***
assists	0,0471902	0,0157265	3,001	0,0027 ***
expected_goals	0,0220395	0,0193036	1,142	0,2537
expected_assists	0,105267	0,0187181	5,624	2,13e-08 ***
total_shots	0,00205313	0,00342488	0,5995	0,5489
shots_on_target	0,00234048	0,00885901	0,2642	0,7917
yellow_cards	-0,00265452	0,00971781	-0,2732	0,7848
red_cards	0,0108242	0,0435455	0,2486	0,8037
tackles	-0,00157804	0,00183956	-0,8578	0,3911
interceptions	0,00959646	0,00289668	3,313	0,0009 ***
age_new	0,154540	0,0534246	2,893	0,0039 ***
sq_age_new	-0,00520696	0,000974943	-5,341	1,03e-07 ***
top_club	1,02519	0,0385822	26,57	2,57e-133 ***
Dleague_1	-2,39227	0,0712211	-33,59	3,65e-196 ***
Dleague_2	-0,989236	0,0500619	-19,76	1,79e-079 ***
Dleague_3	-1,00953	0,0485442	-20,80	4,80e-087 ***
Dleague_4	-0,793972	0,0462996	-17,15	1,43e-061 ***
Dleague_5	-1,10281	0,0560970	-19,66	9,54e-079 ***
Dleague_6	-2,19268	0,0803604	-27,29	1,95e-139 ***
Dpos_fbref_1	-0,0412008	0,0522225	-0,7889	0,4302
Dpos_fbref_2	-0,0131868	0,0716389	-0,1841	0,8540
l_minutes_played	0,949635	0,224486	4,230	2,44e-05 ***
Średn.aryt.zm.zależnej	15,59413	Odch.stand.zm.zależnej	1,444419	
Suma kwadratów reszt	1269,515	Błąd standardowy reszt	0,800528	
Wsp. determ. R-kwadrat	0,696515	Skorygowany R-kwadrat	0,692838	
F(24, 1981)	231,3582	Wartość p dla testu F	0,000000	
Logarytm wiarygodności	-2387,511	Kryt. inform. Akaike'a	4825,022	
Kryt. bayes. Schwarza	4965,119	Kryt. Hannana-Quinna	4876,455	
Wyłączając stałą, największa wartość p jest dla zmiennej 36 (Dpos_fbref_2)				

Załącznik 5: Wykaz klubów top_club

klub_elity	Definicja top_club: globalne marki + kluby lig Big 5 grające w Lidze Mistrzów 2025/26.									
Liverpool	top_club=1, gdy klub zawodnika (kolumna club) znajduje się na tej liście.									
Arsenal	LM 2025/26 (Big5, 22 kluby) + marki spoza LM: Manchester Utd, Milan.									
Manchester City										
Newcastle United										
Chelsea										
Tottenham Hotspur										
Barcelona										
Real Madrid										
Atlético Madrid										
Athletic Club										
Villarreal										
Napoli										
Inter										
Atalanta										
Juventus										
Bayern Munich										
Leverkusen										
Eintracht Frankfurt										
Dortmund										
Paris Saint-Germain										
Marseille										
Monaco										
Manchester Utd										
Milan										

Załącznik 6: Model referencyjny spełniający klasyczne założenia KMNK

Model 3: Estymacja KMNK, wykorzystane obserwacje 1-2006
Zmienna zależna (Y): l_market_value

	współczynnik	błąd standardowy	t-Studenta	wartość p	
const	2,41284	1,09814	2,197	0,0281	**
goals	0,0607690	0,0110178	5,516	3,93e-08	***
assists	0,0536080	0,0175012	3,063	0,0022	***
tackles	0,00685482	0,00251375	2,727	0,0064	***
interceptions	-0,00653458	0,00401129	-1,629	0,1035	
rating	1,88623	0,166633	11,32	7,75e-029	***

Średn.aryt.zm.zależnej	15,59413	Odch.stand.zm.zależnej	1,444419
Suma kwadratów reszt	3469,763	Błąd standardowy reszt	1,317149
Wsp. determ. R-kwadrat	0,170533	Skorygowany R-kwadrat	0,168460
F(5, 2000)	82,23758	Wartość p dla testu F	1,06e-78
Logarytm wiarygodności	-3395,978	Kryt. inform. Akaike'a	6803,956
Kryt. bayes. Schwarza	6837,579	Kryt. Hannana-Quinna	6816,300

Wyłączając stałą, największa wartość p jest dla zmiennej 19 (interceptions)

Test RESET na specyfikację -

Hipoteza zerowa: specyfikacja poprawna
Statystyka testu: $F(2, 1998) = 2,83527$
z wartością $p = P(F(2, 1998) > 2,83527) = 0,0589387$

Test White'a na heteroskedastyczność reszt (zmienność wariancji resztowej) (tylko kwadrat zmiennej zależnej $\hat{y}$) -

Hipoteza zerowa: heteroskedastyczność reszt nie występuje
Statystyka testu: $LM = 16,2682$
z wartością $p = P(\text{Chi-kwadrat}(10) > 16,2682) = 0,0922075$